

UNIVERSIDAD NACIONAL FEDERICO VILLARREAL
Ingeniería Informática
Curso: Inteligencia Artificial

**Sistema inteligente basado en aprendizaje automático
para identificar hogares en situación de pobreza
monetaria a partir de características observables,
como apoyo a la focalización de programas sociales
en el Perú**

Proyecto de investigación aplicada con datos reales de la
Encuesta Nacional de Hogares (ENAHOG) 2024-2025 del INEI

Autor: Nina Anchapuri Brens Fabrizio Leandro

Docente: Rodríguez Rodríguez, Ciro

Lima, Perú
Septiembre de 2026

Índice

Resumen y palabras clave	2
Abstract	2
4 Introducción	3
5 Situación problemática	4
6 Identificación y formulación del problema	4
7 Pregunta de investigación	5
8 Objetivos	5
9 Justificación	6
10 Antecedentes y estado del arte	7
11 Marco conceptual	8
12 Metodología de investigación	9
13 Metodología de desarrollo de la solución	9
14 Comprensión del problema	9
15 Comprensión de los datos	10
16 Ingeniería y preparación de datos	11
16.1 Data card del dataset	11
16.2 Calidad de los datos	12
16.3 Análisis exploratorio de datos	12
16.4 Preparación e ingeniería de datos	13
16.5 Prevención de la fuga de información	14
17 Diseño de la solución	16
17.1 Técnicas de ingeniería de software	17
18 Desarrollo e implementación	17
18.1 Diseño del modelo de inteligencia artificial	17
18.2 Modelo base (baseline)	18
18.3 Implementación del prototipo	18
19 Diseño experimental	20
20 Evaluación	20
21 Resultados	21
22 Discusión	24
23 Amenazas a la validez y limitaciones	25
24 Consideraciones éticas	26
25 Reproducibilidad	26
26 Conclusiones	26
27 Recomendaciones y trabajo futuro	27
28 Referencias	27
29 Anexos	30
Anexo A. Descripción completa del dataset	30
Anexo B. Código fuente y repositorio	30
Anexo C. Diccionario de datos	30
Anexo D. Resultados completos	32
Anexo E. Configuración de los experimentos	33
Anexo F. Instrumentos utilizados	34
Anexo G. Diagramas UML	34
Anexo H. Capturas del prototipo	38
Anexo I. Matriz de trazabilidad final	40

Resumen

En el Perú, la pobreza monetaria afectó al 25,7 % de la población en 2025 (8,8 millones de personas). Su medición oficial usa el gasto del hogar, que no puede recogerse en cada solicitante; por eso la focalización de programas sociales recurre a características observables y a reglas simples que producen errores de exclusión e inclusión. Este trabajo tuvo como objetivo desarrollar un sistema inteligente basado en aprendizaje automático que identifique hogares en situación de pobreza monetaria a partir de características observables. Se usaron microdatos reales de la Encuesta Nacional de Hogares (ENAH) 2024 y 2025 del INEI: 33 702 hogares de 2025 con 36 variables observables, sin ingresos ni gastos para evitar la fuga de información. Con CRISP-DM y Design Science Research, se compararon una regla sin inteligencia artificial («rural = pobre»), regresión logística, árbol de decisión, KNN y Random Forest, con el mismo pipeline, validación cruzada estratificada, un conjunto de prueba reservado y una validación temporal 2024–2025 sin hogares repetidos. La regresión logística con balanceo de clases, elegida con una regla fijada de antemano, obtuvo en la prueba un F1 de 0,544, un *recall* de 0,798 y un ROC-AUC de 0,853, frente a un F1 de 0,334 de la regla: detectó 383 hogares pobres más y cometió 336 errores de inclusión menos. Mantuvo su desempeño al año siguiente y empató con Random Forest, menos interpretable. El análisis de equidad reveló más errores de exclusión en hogares urbanos, con jefa mujer y de la costa. El modelo se integró en un prototipo web que explica cada predicción. Se concluye que el aprendizaje automático mejora la identificación de hogares pobres frente a una regla simple, como apoyo y no como reemplazo de la verificación oficial.

Palabras clave: pobreza monetaria; focalización de programas sociales; aprendizaje automático; regresión logística; ENAH; Perú.

Abstract

In Peru, monetary poverty affected 25.7 % of the population in 2025 (8.8 million people). Its official measurement uses household expenditure, which cannot be collected for every applicant; therefore, social program targeting relies on observable characteristics and simple rules that produce exclusion and inclusion errors. This work aimed to develop an intelligent system based on machine learning that identifies households in monetary poverty from observable characteristics. We used real microdata from the 2024 and 2025 National Household Survey (ENAH) of INEI: 33,702 households from 2025 with 36 observable variables, excluding income and expenditure to prevent data leakage. Following CRISP-DM and Design Science Research, we compared a non-AI rule (“rural = poor”), logistic regression, a decision tree, KNN and random forest, using the same pipeline, stratified cross-validation, a held-out test set and a 2024–2025 temporal validation without repeated households. Class-weighted logistic regression, selected with a rule fixed in advance, achieved on the test set an F1 of 0.544, a recall of 0.798 and a ROC-AUC of 0.853, versus an F1 of 0.334 for the rule: it detected 383 more poor households and made 336 fewer inclusion errors. Its performance held in the following year and tied with random forest, which is less interpretable. The fairness analysis revealed more exclusion errors among urban households, female-headed households and coastal regions. The model was integrated into a web prototype that explains each prediction. We conclude that machine learning improves the identification of poor households compared with a simple rule, as support for, not a replacement of, official verification.

Keywords: monetary poverty; social program targeting; machine learning; logistic regression; ENAH; Peru.

4. Introducción

Los programas sociales de transferencias, como Juntos (hogares pobres con niñas, niños o gestantes) y Pensión 65 (adultos mayores en pobreza extrema), son uno de los principales instrumentos del Estado peruano contra la pobreza. Para que lleguen a quienes los necesitan, el Estado debe *focalizar*, es decir, identificar qué hogares son pobres. Esta tarea se organiza en el Sistema Nacional de Focalización [1] y se apoya en el Sistema de Focalización de Hogares (SISFOH), que asigna una clasificación socioeconómica a partir de información del hogar [2]. La medición oficial de la pobreza, en cambio, la realiza el Instituto Nacional de Estadística e Informática (INEI) con la Encuesta Nacional de Hogares (ENAHOG): una persona es pobre si el gasto per cápita de su hogar no alcanza el costo de una canasta básica [3]. Como medir el gasto exige una entrevista extensa que no puede hacerse a cada solicitante, la focalización recurre en todo el mundo a *proxy means tests*: puntajes que estiman la condición del hogar con características fáciles de observar, como los materiales de la vivienda o los bienes que posee [4,5].

En 2025, la pobreza monetaria afectó al 25,7 % de la población peruana, 8,8 millones de personas, y superó en 5,5 puntos porcentuales su nivel previo a la pandemia [3]. Identificar a esos hogares es difícil. El 74,1 % de las personas pobres vive en zonas urbanas [3], por lo que los criterios geográficos simples dejan fuera a gran parte de ellas. Además, las mismas condiciones no significan lo mismo en todo el país: la línea de pobreza extrema va de S/ 210 por persona al mes en la Selva rural a S/ 307 en Lima Metropolitana. Los microdatos de la ENAHOG 2025 muestran las consecuencias: el 59,3 % de los hogares que reciben Juntos no es pobre según el INEI, y solo el 18,1 % de los hogares pobres recibe ese programa (sección 5). Cada error de exclusión deja sin apoyo a un hogar pobre, y cada error de inclusión consume recursos que no llegan a quien los necesita. Mejorar la identificación de los hogares pobres aumenta, por lo tanto, el impacto del mismo presupuesto.

La literatura muestra que los *proxy means tests* basados en regresión filtran bien a los no pobres, pero excluyen a muchos pobres [6], y que el aprendizaje automático evaluado fuera de muestra puede mejorar su desempeño [7,8]. En el Perú, estudios recientes aplicaron árboles de decisión, Random Forest y redes neuronales a la ENAHOG y reportaron exactitudes cercanas al 98 % [9,10]. Sin embargo, al menos dos de ellos usan el gasto del hogar como predictor [10,11], que es justamente la variable con la que se define la pobreza. Un modelo así no sirve para focalizar, porque el gasto no se conoce al momento de decidir, y su desempeño está inflado por la fuga de información (*data leakage*) [12]. Falta evidencia, con los datos más recientes del país, de cuánto mejora el aprendizaje automático a una regla simple cuando se usan *solo* características observables, de si ese desempeño se mantiene de un año a otro y de a qué grupos afectan sus errores.

Este trabajo propone un sistema inteligente que estima el riesgo de que un hogar sea pobre a partir de 36 características observables, entrenado con la ENAHOG 2025 y evaluado frente a una regla sin inteligencia artificial. El desarrollo siguió CRISP-DM dentro de un enfoque de Design Science Research [13,14]. El trabajo hace tres contribuciones. La primera es evidencia reproducible y sin fuga de información: el dataset se construye de forma automatizada desde los microdatos oficiales, reproduce exactamente las cifras del INEI y se valida también con otro año. La segunda es una comparación controlada de cuatro algoritmos frente a una regla sin inteligencia artificial, con métricas que separan los errores de exclusión y de inclusión, un análisis de interpretabilidad y un análisis de equidad por grupos. La tercera es un prototipo web que explica cada predicción y ordena listas de hogares, acompañado de pruebas automatizadas y un repositorio documentado.

5. Situación problemática

La tabla 1 reúne la evidencia de que el problema existe. Proviene de cuatro tipos de fuentes: estadísticas oficiales, microdatos analizados en este proyecto, una evaluación institucional y literatura científica.

Tabla 1. Evidencia de la situación problemática.

Indicador	Valor	Fuente y observación
Personas en pobreza monetaria, 2025	25,7 % (8,8 millones)	INEI [3]; 5,5 puntos más que en 2019
Pobres que viven en zonas urbanas	74,1 %	INEI [3]; replicado con los microdatos
Línea de pobreza extrema por dominio	S/ 210 a S/ 307	INEI [3]; Selva rural frente a Lima Metropolitana
Hogares que reciben Juntos / Pensión 65 y no son pobres	59,3 % / 69,0 %	ENAH0 2025, módulos 34 y 37, ponderado
Hogares pobres que reciben Juntos / Pensión 65	18,1 % / 13,6 %	ENAH0 2025, ponderado
Hogares pobres que la regla «rural = pobre» deja fuera	51,6 %	Conjunto de prueba de este proyecto (tabla 15)
Enfoque operativo del SISFOH	Por demanda	Prioriza evitar la filtración y acepta errores de exclusión [2]
<i>Proxy means tests</i> basados en regresión	Excluyen a muchos pobres	Evidencia de nueve países [6]

Los indicadores de programas sociales deben leerse con cautela: la pobreza se mide después de recibir la transferencia, cada programa tiene requisitos propios y los programas usan la clasificación del SISFOH y no el gasto de la ENAH0. Aun así, la magnitud de las cifras, junto con la evaluación institucional [2] y la evidencia internacional [6], muestra que identificar correctamente a los hogares pobres es un problema real, vigente y difícil en el Perú.

6. Identificación y formulación del problema

El problema se analizó con un árbol de problemas (figura 1), en el que cada causa y cada efecto se sustenta en la evidencia de la tabla 1; los actores involucrados se analizan en la sección 14.

Problema general. Los programas sociales del Perú no identifican con suficiente precisión a los hogares en situación de pobreza monetaria: dejan fuera a hogares pobres e incluyen a hogares no pobres.

Causas. (C1) La medición del gasto es costosa y no se aplica a cada hogar; (C2) las reglas y puntajes simples no capturan la pobreza urbana; (C3) el costo de vida varía entre dominios; (C4) el sistema opera por demanda y tolera la exclusión.

Consecuencias. Hogares pobres excluidos, filtración hacia hogares no pobres y menor impacto del gasto social.

Evidencias. Tabla 1.

Necesidad. Clasificar a los hogares como pobres o no pobres, y ordenarlos por riesgo, usando solo información observable en una visita, con más acierto que una regla simple y de forma explicable.




Figura 1. Árbol de problemas: causas (abajo), problema central y efectos (arriba).

7. Pregunta de investigación

La pregunta general es: *¿en qué medida un modelo de aprendizaje automático entrenado con características observables del hogar permite identificar a los hogares en situación de pobreza monetaria mejor que una regla de focalización simple, utilizando datos reales de la ENAHO?* Se desagrega en seis preguntas específicas:

- PE1. ¿Qué características observables se asocian con la pobreza y qué evidencia muestra que una regla simple es insuficiente?
- PE2. ¿Cómo deben prepararse los datos de la ENAHO para entrenar modelos sin fuga de información?
- PE3. ¿Qué algoritmos de aprendizaje supervisado pueden implementarse y cómo se ajustan?
- PE4. ¿Qué desempeño alcanzan frente a la regla simple en datos no vistos y en otro año?
- PE5. ¿Qué modelo es el mejor, considerando también la interpretabilidad, la equidad y la eficiencia?
- PE6. ¿Puede integrarse el modelo en un prototipo que apoye la priorización de hogares?

La hipótesis de trabajo (H1) es que, en datos no vistos, el mejor modelo obtiene un F1 mayor que la regla «rural = pobre» y reduce a la vez los errores de exclusión y de inclusión. La hipótesis nula (H0) es que no la supera en F1 o que mejora un tipo de error solo a costa del otro.

8. Objetivos

El **objetivo general** es desarrollar un sistema inteligente basado en aprendizaje automático que identifique hogares en situación de pobreza monetaria a partir de características observables,

utilizando datos reales de la ENAHO del INEI, con la finalidad de apoyar la focalización de programas sociales en el Perú. Los **objetivos específicos** son:

- OE1** Analizar las características del hogar asociadas a la pobreza monetaria mediante la revisión de literatura y el análisis exploratorio de los datos de la ENAHO.
- OE2** Diseñar un proceso de preparación de los datos que construya un conjunto adecuado para el entrenamiento, sin fuga de información.
- OE3** Diseñar e implementar modelos de aprendizaje automático (regresión logística, árbol de decisión, KNN y Random Forest) para identificar hogares pobres.
- OE4** Evaluar experimentalmente los modelos con métricas apropiadas, en un conjunto de prueba reservado y en una validación temporal.
- OE5** Comparar los resultados y determinar el modelo con mejor desempeño bajo las condiciones experimentales establecidas.
- OE6** Implementar un prototipo funcional que integre el modelo seleccionado para apoyar la priorización de hogares.

La tabla 2 presenta la matriz de trazabilidad, que vincula cada causa o necesidad con una pregunta, un objetivo, un método y la evidencia que lo verifica. La matriz final, con los resultados obtenidos, está en el anexo I.

Tabla 2. Matriz de trazabilidad metodológica.

Problema	Pregunta	Obj.	Método	Resultado esperado	Evidencia
Errores en la identificación de hogares pobres	General	OG	CRISP-DM + DSR	Sistema que identifica hogares pobres mejor que una regla	Tablas 15 y 16
C2, C3: reglas simples y costo de vida	PE1	OE1	Literatura y análisis exploratorio	Factores asociados y evidencia contra la regla	Figuras 4–6
C1: el gasto no está disponible	PE2	OE2	Preparación de datos y control de fuga	Dataset preparado sin fuga	Tablas 8 y 9
Necesidad de predecir	PE3	OE3	Aprendizaje supervisado con GridSearchCV	Modelos entrenados	Tabla 14
Necesidad de evaluar	PE4	OE4	Experimentos E0–E6	Métricas en prueba y en otro año	Tablas 15, 16 y 17
Necesidad de seleccionar	PE5	OE5	Regla de selección fijada de antemano	Mejor modelo justificado	Sección 21
C4 y consecuencias: decisión y uso	PE6	OE6	Prototipo y pruebas automatizadas	Artefacto funcional	Figura 8 y tabla 11

9. Justificación

Práctica. El proyecto ayuda a decidir a qué hogares priorizar cuando no se conoce su gasto. Detectar más hogares pobres e incluir menos no pobres permite que el mismo presupuesto tenga más impacto [5].

Tecnológica. Ninguna característica aislada separa a pobres de no pobres (sección 16.3). El aprendizaje automático combina decenas de características y aprende sus pesos a partir de datos reales, en lugar de fijar reglas a mano [7]. La comparación con una regla sin inteligencia artificial mide cuánto valor agrega.

Científica. El trabajo aporta evidencia, con la edición más reciente de la ENAHO, sobre el desempeño realista de modelos sin fuga de información, su estabilidad entre años y sus brechas entre grupos. Así contrasta con los estudios que reportan exactitudes cercanas al 98 % usando el gasto como predictor [10].

Metodológica. CRISP-DM [15] organiza el ciclo de datos y modelado, y Design Science Research [13, 14], la construcción y evaluación del artefacto. A ellos se suman prácticas de ingeniería de software para aprendizaje automático [16]: requisitos, arquitectura, pruebas, control de versiones y reproducibilidad.

10. Antecedentes y estado del arte

La revisión abarcó tres líneas: la focalización con *proxy means tests*, el aprendizaje automático aplicado a la focalización y los estudios con aprendizaje automático sobre la pobreza en el Perú. La tabla 3 resume, para cada antecedente, el problema, los datos, el método, las métricas, los resultados, la limitación y su relación con este proyecto.

Grosh y Baker [4] propusieron estimar la condición del hogar con un puntaje de características observables cuando medir el ingreso es costoso, y Coady et al. [5] mostraron que el método de focalización influye en cuánto del presupuesto llega a los pobres. Sin embargo, Brown et al. [6] encontraron en nueve países africanos que los puntajes calibrados con regresión filtran bien a los no pobres pero excluyen a muchos pobres, y Karlan y Thuysbaert [17] hallaron, en Honduras y el Perú, que distintos métodos identifican bien los extremos de la distribución pero tienen resultados mixtos en el medio. En la segunda línea, McBride y Nichols [7] mostraron que priorizar el error fuera de muestra, con validación cruzada y ensambles como Random Forest, mejora las herramientas de focalización. Sohnesen y Stender [18] advirtieron que Random Forest suele predecir mejor en el mismo año, pero que ningún método es consistente de un año a otro. Noriega-Campero et al. [8] y Aiken et al. [19] mostraron que la focalización algorítmica amplía la cobertura de pobres frente a los métodos vigentes o geográficos, pero genera disparidades entre grupos y, en el caso de Aiken et al., requiere datos de telefonía que no son públicos en el Perú.

En el Perú, Silva Marchan et al. [9], Vargas Mamani [10] y Caycho [11] aplicaron aprendizaje automático a la ENAHO. Los dos primeros reportan exactitudes de 98 %, y en los dos últimos el gasto del hogar figura como el principal predictor. Como la pobreza monetaria se define comparando el gasto per cápita con la línea de pobreza [3], usar el gasto como predictor equivale a darle la respuesta al modelo [12]. En síntesis, la literatura internacional demuestra que el aprendizaje automático puede mejorar la focalización, pero no usa datos peruanos recientes, mientras que los estudios peruanos usan la ENAHO pero incluyen el gasto o se limitan al *accuracy*, sin baseline, sin validación temporal y sin una herramienta utilizable. Este proyecto se ubica en ese vacío.

Tabla 3. Análisis de antecedentes.

Estudio	Problema y datos	Método y algoritmo	Métricas y resultados	Limitación	Relación con el proyecto
Brown et al. [6]	Desempeño de los <i>proxy means tests</i> ; encuestas de 9 países africanos	Puntajes calibrados con regresión del consumo	Errores de inclusión y exclusión; los puntajes excluyen a muchos pobres	Sin aprendizaje automático	Motiva medir la exclusión (<i>recall</i>)
Karlan y Thuysbaert [17]	Hogares ultra pobres en Honduras y el Perú	Ranking participativo frente a dos <i>proxy means tests</i>	Aciertan en los extremos y fallan en el medio	Programas específicos	Anticipa errores en hogares del medio

Estudio	Problema y datos	Método y algoritmo	Métricas y resultados	Limitación	Relación con el proyecto
McBride y Nichols [7]	Mejorar los <i>proxy means tests</i> ; datos de USAID	Validación cruzada y Random Forest	Mejora sustancial fuera de muestra	Sin validación temporal	Justifica la validación cruzada y Random Forest
Sohnesen y Stender [18]	Predicción de la pobreza; encuestas de 6 países	Random Forest frente a <i>stepwise</i> y Lasso	Mejor en el mismo año; inconsistente entre años	Predice tasas, no hogares	Motiva la validación temporal
Noriega-Campero et al. [8]	Focalización de políticas sociales en 2 países	Inteligencia artificial frente a los sistemas vigentes	Casi un millón más de pobres cubiertos; disparidades entre grupos	Brechas sin restricciones de paridad	Motiva el análisis de equidad
Aiken et al. [19]	Ayuda humanitaria en Togo; encuestas y telefonía	Aprendizaje automático con datos de telefonía	Exclusión 4-21 % menor que la geográfica	Datos privados de operadores	Compara con una regla geográfica
Silva Marchan et al. [9]	Riesgo de pobreza; ENAHO 2020, 91 315 registros	Árbol, Random Forest, Naive Bayes, regresión logística y SVM	<i>Accuracy</i> de 98 %	Solo <i>accuracy</i> ; sin baseline reportado	Se usan F1, <i>recall</i> y <i>precision</i>
Vargas Mamani [10]	Factores de pobreza; ENAHO 2023, 86 183 personas	Perceptrón multicapa	<i>Accuracy</i> de 98,55 %; factor principal: gasto anual	El gasto define la pobreza (fuga)	Se excluyen gasto e ingreso
Caycho [11]	Clasificación de hogares pobres; ENAHO, 21 variables	Árboles de decisión	Determinantes: gasto per cápita, miembros, piso de tierra	Gasto como predictor	Coincide en miembros y piso sin usar el gasto

11. Marco conceptual

La *inteligencia artificial* estudia agentes que perciben su entorno y actúan para lograr objetivos [20]; el *aprendizaje automático* es la rama que construye sistemas que mejoran en una tarea a partir de datos, en lugar de reglas programadas a mano. En el aprendizaje *supervisado*, el modelo aprende de ejemplos con una *variable objetivo* conocida [21]: si es una categoría, el problema es de *clasificación*; si es un valor continuo, de *regresión*. Este proyecto es de clasificación binaria: la variable objetivo es **pobre** y las *características* (*features*) son 36 variables observables del hogar. El modelo se ajusta con un conjunto de *entrenamiento*, sus hiperparámetros se eligen con *validación* (aquí, validación cruzada de cinco particiones) y su desempeño final se mide una sola vez con un conjunto de *prueba* [21]. La *generalización* es la capacidad de acertar con datos nuevos; hay *sobreaajuste* cuando el modelo memoriza el entrenamiento y rinde peor en datos nuevos, y *subajuste* cuando es demasiado simple y rinde mal en ambos [21].

La *regresión logística* estima la probabilidad de la clase positiva con una combinación lineal de las variables transformada por la función logística [21]. El *árbol de decisión* divide los datos con reglas «si... entonces...», el *Random Forest* promedia muchos árboles entrenados con muestras y variables aleatorias [22], y *KNN* asigna a cada caso la clase de sus *k* vecinos más cercanos [21]. Cuando una clase es minoritaria, el *accuracy* engaña, porque predecir siempre la clase mayoritaria parece un buen resultado [23]; por eso se usan la *precision* (proporción de casos marcados como positivos que lo son), el *recall* (proporción de positivos detectados), su media armónica F1 y el área bajo la curva ROC, que mide la capacidad de ordenar los casos por riesgo [24].

Una persona está en *pobreza monetaria* si el gasto per cápita de su hogar es menor que la línea de pobreza, el valor de una canasta básica de alimentos y otros bienes [3]. La *focalización* identifica a la población objetivo de un programa; un *proxy means test* lo hace con características

observables [4]. El *error de exclusión* ocurre cuando un hogar pobre queda fuera, y el *error de inclusión* o filtración, cuando un hogar no pobre recibe el beneficio [5]. La *fuga de información* ocurre cuando el modelo usa al entrenar información que no tendría al predecir, lo que produce métricas engañosamente buenas [12]. Por último, la *interpretabilidad* es la capacidad de explicar por qué un modelo decide algo, y en decisiones de alto impacto se recomienda preferir modelos interpretables cuando rinden igual [25]; la *equidad algorítmica* estudia si un modelo comete errores sistemáticamente distintos entre grupos [26].

12. Metodología de investigación

La investigación tiene un **enfoque** cuantitativo, porque la pregunta se responde con métricas calculadas sobre datos reales, y es de **tipo** aplicada y tecnológica, porque busca resolver un problema práctico con un artefacto de software. Su **diseño** es Design Science Research [13, 14], con una evaluación experimental controlada del artefacto: varios tratamientos (algoritmos) se comparan con un control (la regla sin inteligencia artificial) manteniendo constantes los datos, la preparación y las particiones. Las seis actividades de Peffers et al. [14] se cumplen así: el problema se identifica en las secciones 5 y 6; los objetivos de la solución se definen en las secciones 8 y 14; el diseño y desarrollo se describen en las secciones 16 a 18; la demostración y la evaluación, en las secciones 19 a 21; y la comunicación se hace con este artículo y el repositorio.

La población son los hogares del Perú. La muestra son los 33 702 hogares de la ENAHO 2025, seleccionados por el INEI con un diseño probabilístico, estratificado y por conglomerados, más los 33 691 hogares de la ENAHO 2024 usados en la validación temporal. La unidad de análisis es el hogar. Los datos son secundarios y oficiales: microdatos descargados del portal del INEI [27], cuyo instrumento original es el cuestionario de la ENAHO (anexo F). El análisis se realizó con Python y scikit-learn [28].

13. Metodología de desarrollo de la solución

Se utilizó CRISP-DM junto con Design Science Research y prácticas de ingeniería de software (figura 2). CRISP-DM organiza el ciclo de datos y modelado en seis fases y sigue siendo el estándar de facto, aunque la mayoría de los estudios no documenta la fase de despliegue [15]; por eso aquí se documenta con el prototipo, las pruebas y el repositorio. La cadena ampliada que propone el curso se implementó de la siguiente manera: el problema y los requisitos se analizan en las secciones 5 a 14; los datos, en las secciones 15 y 16; el diseño y la implementación, en las secciones 17 y 18; y la evaluación, en las secciones 19 a 21. El despliegue es un prototipo que se ejecuta con un solo comando, y el mantenimiento consiste en reentrenar el modelo con cada nueva edición de la ENAHO usando los mismos scripts, con control de versiones en Git.

14. Comprensión del problema

El proceso de focalización vigente funciona por demanda [2]. El hogar solicita su clasificación socioeconómica en la municipalidad, la unidad local de empadronamiento recoge sus datos con una ficha, el SISFOH calcula la clasificación y cada programa aplica sus propios criterios de elegibilidad. El sistema propuesto no reemplaza este proceso: es una herramienta de apoyo que estima el riesgo de pobreza con información observable, lo explica y ordena listas de hogares, por ejemplo, para priorizar visitas de verificación.

Los principales actores son cinco. Los hogares en situación de pobreza son los sujetos de la decisión, tienen poca influencia y su interés es no quedar excluidos. Los programas sociales, el MIDIS y el SISFOH tienen alta influencia y buscan llegar a su población objetivo con un presupuesto limitado. Las municipalidades recogen los datos del hogar. El analista de focalización




Figura 2. Fases de CRISP-DM, actividades de Design Science Research y artefactos del repositorio.

es el usuario del prototipo y necesita priorizar y justificar decisiones. El INEI es el proveedor de los datos de entrenamiento. El proyecto tuvo cuatro restricciones: usar solo datos públicos y anónimos, usar solo información disponible en una visita (sin gasto ni ingreso), limitarse a las técnicas del curso y trabajar en una computadora personal.

La tabla 4 presenta los requisitos y cómo se verifica cada uno. Se fijaron cinco criterios de éxito:

CE1: en la prueba, el modelo supera a la regla en F1 y reduce los dos tipos de error;

CE2: el desempeño se mantiene al entrenar con un año y evaluar con hogares nuevos del siguiente;

CE3: la ausencia de fuga de información se verifica de forma explícita;

CE4: cada predicción puede explicarse;

CE5: el prototipo cumple los requisitos.

Los riesgos identificados se mitigaron así: la fuga de información, con variables observables y preprocesamiento dentro del pipeline; el desbalance de clases, con F1 como métrica principal y balanceo de clases; el sesgo entre grupos, con un análisis de equidad; el cambio en el tiempo, con validación temporal; y el uso como decisión automática, presentando el prototipo como apoyo y con advertencias explícitas.

15. Comprensión de los datos

Los datos provienen de la ENAHO, la encuesta continua con la que el INEI mide la pobreza monetaria [3]. Sus microdatos se publican de forma anónima [27], y el script `src/data/descargar.py` los descarga para que cualquier persona pueda reconstruir el mismo dataset. La tabla 5 presenta la ficha del dataset.

Para demostrar que los datos son reales y que se procesan correctamente, se reprodujeron las cifras oficiales de pobreza con los microdatos, ponderando cada hogar por su factor de expansión y su número de miembros. La coincidencia fue exacta en los ocho ámbitos comparados: 25,7 % nacional, 23,4 % urbana, 35,5 % rural y los cinco departamentos más pobres (Cajamarca, Loreto, Puno, Pasco y Huánuco). Con la ENAHO 2024 se reprodujo también la cifra oficial de ese año (27,6 %). De los 33 702 hogares, 6 104 (18,1 %) son pobres. Este porcentaje es menor que el de personas pobres porque los hogares pobres son más grandes (4,06 miembros frente a 2,99). La

Tabla 4. Requisitos funcionales (RF) y no funcionales (RNF).

ID	Requisito	Verificación
RF1	Registrar las características observables de un hogar y validar su consistencia	Pruebas funcionales y de integración
RF2	Calcular las variables derivadas con las mismas funciones del entrenamiento	Prueba de integración
RF3	Estimar la probabilidad de pobreza y la decisión según el umbral	Prueba de integración
RF4	Explicar la predicción por grupo temático y por característica	Prueba de integración (suma exacta)
RF5	Evaluar, ordenar y descargar una lista de hogares (CSV o muestra de la ENAHO)	Pruebas funcionales y verificación manual
RF6	Informar el desempeño, la equidad y las limitaciones del modelo	Prueba funcional
RNF1	Tiempo de respuesta menor de 1 segundo por hogar	Prueba de validación
RNF2	Robustez ante faltantes, textos y códigos inválidos	Pruebas de validación e integración
RNF3	Interpretabilidad: explicación exacta de cada predicción	Prueba de integración
RNF4	Reproducibilidad: mismos resultados con los mismos datos y semilla	Pruebas de partición y de métricas
RNF5	Privacidad: no almacenar ni enviar datos de los hogares	Revisión de código
RNF6	Portabilidad y usabilidad: cuadernos preparados para Windows y Colab; interfaz en español con categorías en palabras	Ejecución completa en Windows 11 y revisión de la interfaz

Tabla 5. Ficha del dataset.

Característica	Descripción
Fuente y propietario	ENAHO 2025 del Instituto Nacional de Estadística e Informática (INEI); la ENAHO 2024 se usa en la validación temporal
Módulos	01 vivienda, 02 miembros, 03 educación, 18 equipamiento y 34 sumaria (objetivo y ubicación); el 37 (programas sociales) solo evidencia el problema
Fecha de adquisición	24 de septiembre de 2026, con descarga automatizada
Periodo y cobertura	Enero a diciembre de 2025; nacional, 25 departamentos, áreas urbana y rural
Registros	33 702 hogares (2025) y 33 691 hogares (2024)
Variables	36 predictoras (10 numéricas, 10 categóricas y 16 binarias), 1 objetivo y 6 de identificación
Unidad de análisis	Hogar (llave CONGLOME + VIVIENDA + HOGAR)
Variable objetivo	pobre : 1 si el hogar es pobre extremo o no extremo ($\text{POBREZA} \leq 2$); 0 si no
Formato	CSV (separador «;» y coma decimal en 2025; «.» y punto decimal en 2024)
Procedencia	Muestreo probabilístico, estratificado y por conglomerados, con entrevista directa
Licencia y permiso	Acceso libre y anónimo, protegido por el secreto estadístico [29]; uso citando la fuente

clase positiva es minoritaria, lo que obliga a usar métricas distintas del *accuracy* y a considerar el balanceo de clases.

16. Ingeniería y preparación de datos

16.1. Data card del dataset

La tabla 6 sigue la propuesta de *datasheets for datasets* [30]; las reglas de construcción están en el anexo A y el diccionario de datos, en el anexo C.

Tabla 6. Data card del dataset de hogares.

Campo	Descripción
Origen y adquisición	ENAH0 2025 (INEI); <code>src/data/descargar.py</code> descarga y <code>src/features/construir.py</code> construye
Propósito	Entrenar y evaluar modelos que identifiquen hogares pobres con características observables
Población y unidad	Hogares particulares del Perú; una fila por hogar
Variables y tamaño	36 predictoras de vivienda, servicios, bienes, composición, jefe(a), educación y ubicación; 33 702 hogares, 18,1 % pobres
Calidad	Reproduce las cifras oficiales; reglas lógicas cumplidas (sección 16.2)
Faltantes y duplicados	12,0 % de hogares con al menos un faltante (máximo 7,35 % en una variable); sin duplicados
Sesgos potenciales	Respuestas declaradas; error de medición del gasto que define la etiqueta; poca precisión en grupos pequeños
Limitaciones	Corte transversal anual; la etiqueta depende de líneas de pobreza que varían por dominio
Restricciones éticas y licencia	Datos anónimos de uso estadístico, sin reidentificación; acceso libre citando la fuente [29]

16.2. Calidad de los datos

La tabla 7 evalúa las seis dimensiones de calidad y la figura 3 muestra los faltantes por variable.

Tabla 7. Evaluación de la calidad de los datos.

Dimensión	Resultado	Decisión
Compleitud	17 de 36 variables sin faltantes; máximo en motocicleta (7,35 %) y lavadora (6,27 %); 369 hogares (1,1 %) sin datos de vivienda	Imputación dentro del pipeline, aprendida solo con el entrenamiento
Exactitud	Los microdatos reproducen exactamente las cifras oficiales	Datos aptos
Consistencia	0 contradicciones en 4 reglas lógicas; 1 400 hogares con internet sin electricidad, explicables por internet móvil	Se conservan
Unicidad	0 llaves repetidas y 0 hogares idénticos	No se elimina ningún registro
Validez	595 hogares con un código de combustible inexistente; rangos numéricos plausibles	El código inválido pasa a faltante
Actualidad	Edición 2025, la más reciente (mayo de 2026)	Datos vigentes

16.3. Análisis exploratorio de datos

El análisis usa dos porcentajes: el de *personas* pobres, ponderado con el factor de expansión, que describe al país, y el de *hogares* pobres de la muestra, que es lo que ve el modelo. Con 18,1 % de hogares pobres, un modelo que prediga siempre «no pobre» tendría 81,9 % de *accuracy* sin detectar a ningún pobre. La pobreza varía mucho entre territorios: va de 4,5 % en Ica a 41,0 % en Cajamarca, y Lima (26,3 %) y el Callao (32,1 %) superan el promedio nacional. Aunque la pobreza rural es mayor, la mitad de los hogares pobres de la muestra es urbana (figura 4), así que una regla «rural = pobre» dejaría fuera a la mitad de ellos.

Las características de la vivienda (figura 5) y los bienes del hogar se asocian con la pobreza: la refrigeradora está en el 56,6 % de los hogares no pobres y en el 26,1 % de los pobres, mientras que el celular y la electricidad discriminan poco. Los hogares pobres son más grandes, más




Figura 3. Porcentaje de valores faltantes por variable. **Evidencia:** los faltantes son pocos y se concentran en artículos del hogar, lo que justifica imputarlos en lugar de eliminar hogares.




Figura 4. Pobreza por dominio geográfico y área (% de personas). **Evidencia:** la pobreza rural (35,5 %) supera a la urbana (23,4 %), pero el 74,1 % de las personas pobres vive en zonas urbanas.

hacinados y tienen menos artefactos (figura 6), pero sus distribuciones se superponen con las de los no pobres. Todas las correlaciones con la pobreza son menores de 0,3 en valor absoluto, y hay correlaciones fuertes entre predictoras, como la educación del jefe(a) y la máxima de los adultos (0,77) o los miembros y los menores de 14 años (0,71). Los valores atípicos (hasta 7,0 % en personas por habitación) se conservan porque describen condiciones reales de pobreza, no errores de registro. En cuanto a la evolución temporal, la serie oficial muestra que la pobreza subió de 20,2 % en 2019 a 30,1 % en 2020 y bajó a 25,7 % en 2025 [3]. En conclusión, muchas variables se asocian con la pobreza, pero ninguna la separa por sí sola, lo que justifica un modelo que las combine (respuesta a PE1).

16.4. Preparación e ingeniería de datos

La tabla 8 resume y justifica cada transformación; ninguna se hizo para mejorar las métricas. Las variables derivadas se calculan con una sola función, compartida por la construcción del dataset y el prototipo, para que el modelo reciba los datos calculados igual en el entrenamiento




Figura 5. Porcentaje de hogares pobres según características de la vivienda; la línea marca el promedio (18,1 %). **Evidencia:** el piso de tierra, la leña o el agua de manantial se asocian con más pobreza, pero ninguna categoría supera el 45 %: ninguna característica aislada basta.

y en el uso. La partición estratificada deja 26 961 hogares para el entrenamiento (4 883 pobres) y 6 741 para la prueba (1 221 pobres), y el preprocesador transforma las 36 variables en 119 columnas.

16.5. Prevención de la fuga de información

En el momento real de la predicción, un evaluador visita el hogar y registra lo que puede observar o preguntar de forma verificable, pero *no conoce el gasto ni el ingreso*. La tabla 9 aplica este criterio a cada grupo de información.

Además de excluir las 135 columnas de ingreso, gasto y líneas de pobreza, lo que verifica una prueba automatizada, se tomaron cuatro medidas. El imputador, el escalador y el codificador están dentro del mismo **Pipeline** que el modelo, así que se ajustan solo con el entrenamiento y se reajustan en cada partición de la validación cruzada. Ningún hogar aparece a la vez en entrenamiento y prueba. El conjunto de prueba se usó una sola vez, con el modelo y el umbral ya elegidos. En la validación temporal se excluyeron los 9 842 hogares de 2025 que también fueron entrevistados en 2024, de modo que la evaluación usa solo los 23 860 hogares nuevos. Queda un riesgo menor: la ENAHO selecciona conglomerados de viviendas vecinas, y la división por hogar deja vecinos en ambos conjuntos. No es fuga de la variable objetivo, y su efecto se mide en la sección 23.




Figura 6. Variables numéricas según la condición de pobreza. **Evidencia:** los hogares pobres tienen más miembros (4,06 frente a 2,99), más personas por habitación (1,78 frente a 1,08) y menos artefactos (mediana de 3 frente a 6), pero las cajas se superponen.

Tabla 8. Decisiones de preparación de los datos.

Transformación	Decisión	Justificación
Duplicados	No se requiere eliminar	No hay llaves ni perfiles repetidos
Selección de variables	36 variables observables	Solo lo verificable en una visita; se excluyen 135 columnas monetarias y los programas sociales
<i>Feature engineering</i>	Hacinamiento, dependencia, conteos por edad, jefe(a), educación y total de artefactos	Resumen varios módulos en indicadores con significado socioeconómico
Valores faltantes	Mediana (numéricas) y moda (binarias y categóricas)	La mediana resiste los atípicos; se aprende solo con el entrenamiento
Atípicos	Se conservan	Son situaciones reales del fenómeno
Codificación	One-Hot Encoding	Los códigos del INEI son nominales; tolera categorías nuevas
Estandarización y transformación	StandardScaler ; sin Min-Max ni transformaciones logarítmicas	La regresión logística y KNN son sensibles a la escala; Min-Max es más sensible a extremos; las variables numéricas tienen rangos acotados
Reducción de dimensionalidad	No se aplica	119 columnas frente a 26 961 hogares; PCA impediría interpretar
División	80/20 estratificada, semilla 42	Igual proporción de pobres en ambos conjuntos

Tabla 9. Disponibilidad de la información en el momento de la predicción.

Grupo de información	¿Disponible en la visita?	¿Se usa?
Vivienda, servicios, artefactos, vehículos y comunicaciones	Sí, se observa o se pregunta	Sí
Miembros, edades, sexo, educación y ubicación	Sí, se pregunta o se conoce	Sí
Ingresos, gastos y líneas de pobreza	No: requieren una encuesta de gasto	No (definen la etiqueta)
Condición de pobreza del INEI	No: es lo que se predice	No
Programas sociales y factor de expansión	Consecuencia de la clasificación o dato muestral	No

17. Diseño de la solución

La arquitectura (figura 7) sigue la cadena propuesta por el curso, organizada en tres bloques: los datos (fuente, adquisición y *feature engineering*), el modelo (preprocesamiento, modelo de IA y predicción) y la evaluación y el uso (evaluación, interfaz y usuario). El preprocesamiento se aplica después de construir las variables porque forma parte del *Pipeline* del modelo. La tabla 10 especifica las entradas, los procesos y las salidas de cada componente.




Figura 7. Arquitectura de la solución.

El diseño separa la construcción del modelo, que se hace fuera de línea con los cuadernos, de su uso en línea desde el prototipo. Ambas partes comparten el código que construye las variables del hogar y el modelo guardado. Así, el prototipo calcula las variables igual que en el entrenamiento, y reemplazar el modelo no exige cambiar la interfaz. Se usaron Python 3.10.6, pandas 2.3.3, scikit-learn 1.7.2 [28], Matplotlib y seaborn para los gráficos, joblib para guardar los modelos, Streamlit 1.64 para el prototipo y pytest 9.1 para las pruebas.

Tabla 10. Componentes, entradas, procesos y salidas.

Componente	Entrada	Proceso	Salida
Adquisición (src/data)	Portal del INEI y año	Descarga y lectura de los CSV, detectando separador y decimales	Módulos en memoria
Construcción (src/features)	Módulos 01, 02, 03, 18 y 34	Agregación por hogar, variables derivadas y validez de códigos	Dataset de 33 702 hogares
Preprocesamiento (src/preprocessing)	36 variables	Imputación, estandarización, One-Hot Encoding y partición	119 columnas sin faltantes
Modelo y predicción (src/models)	Ficha o CSV de hogares	Validación, variables derivadas y regresión logística en el Pipeline	Probabilidad y decisión
Evaluación (src/evaluation)	Predicciones y etiquetas	Métricas, validación cruzada y temporal, equidad y explicaciones	Tablas, figuras y aportes
Interfaz (app/app.py)	Acciones del analista	Ficha, lista de hogares y ficha técnica del modelo	Resultados en pantalla y CSV

17.1. Técnicas de ingeniería de software

Los requisitos funcionales y no funcionales se definieron en la sección 14. El modelado incluye la arquitectura y los diagramas UML de casos de uso, componentes y secuencia, que están en el anexo G. En los casos de uso, el actor principal es el analista de focalización, que evalúa un hogar o una lista de hogares, y el desarrollador mantiene el modelo. El código se gestiona con Git, en un repositorio con la estructura recomendada por el curso y un README que explica cómo instalar, obtener los datos y ejecutar el proyecto (anexo B). La lógica vive en `src/`, y tanto los cuadernos como el prototipo la invocan, lo que evita tener dos versiones del mismo cálculo. La calidad se verifica con 51 pruebas automatizadas que se ejecutan con `pytest` y pasan en su totalidad (tabla 11). Las pruebas unitarias usan tablas pequeñas y ficticias solo para verificar reglas del código; la evidencia de desempeño proviene siempre de la ENAHO real.

Tabla 11. Pruebas automatizadas por tipo.

Tipo	Pruebas	Qué verifican
Unitarias	29	Lectura de ambos formatos del INEI, construcción de la variable objetivo, exclusión de variables monetarias, variables derivadas, imputación aprendida solo con el entrenamiento, partición estratificada y disjunta, métricas y regla rural
Integración	10	Carga del modelo, preparación del hogar, predicción, suma exacta de la explicación y robustez ante entradas inválidas
Validación del modelo	6	Reproducción de las métricas reportadas, superioridad frente al baseline y tiempo de respuesta
Funcionales	6	Uso de la aplicación: priorización, mensajes de validación, hogar real y lista de hogares

18. Desarrollo e implementación

18.1. Diseño del modelo de inteligencia artificial

El problema es de clasificación binaria supervisada a nivel de hogar. Además de la clase, el modelo entrega una probabilidad que permite ordenar a los hogares por riesgo. Las entradas son las 36 variables observables (119 columnas tras el preprocesamiento), y la variable objetivo es **pobre**. Se compararon cuatro algoritmos vistos en el curso, que aprenden de maneras distintas

(tabla 12), para saber qué tipo de patrón explica mejor la pobreza. Se descartaron la regresión lineal del gasto, que es el enfoque clásico de los *proxy means tests*, y K-Means. La regresión lineal minimiza el error de predicción del gasto en todo su rango y no los errores de clasificación cerca de la línea de pobreza, y la evidencia muestra que así se excluye a muchos pobres [6]; además, la tarea es reproducir la clasificación oficial y no el monto del gasto. K-Means es no supervisado, y aquí existe una etiqueta oficial. Las redes neuronales y el *boosting* no forman parte del curso y reducen la interpretabilidad. Además, una vez controlada la fuga, los modelos complejos no siempre superan a la regresión logística [12].

Tabla 12. Algoritmos comparados y su pertinencia para el problema.

Algoritmo	Cómo aprende	Por qué es apropiado	Riesgo principal
Regresión logística	Combinación lineal transformada en probabilidad	Base de los <i>proxy means tests</i> ; interpretable y rápida	No capta interacciones no lineales
Árbol de decisión	Reglas «si... entonces...» por umbrales	Capta interacciones; fácil de explicar	Sobreaajuste si crece demasiado
KNN	Clase de los k hogares más parecidos	Hogares parecidos, condición parecida	Sensible a la escala y a la dimensión
Random Forest	Promedio de muchos árboles aleatorizados	Robusto y eficaz en datos tabulares [7]	Menos interpretable y más costoso

La función de pérdida es la medida de error que el entrenamiento busca reducir al mínimo. La regresión logística combina las variables del hogar y convierte el resultado en una probabilidad entre 0 y 1. Para entrenarla, scikit-learn minimiza la pérdida logarítmica (entropía cruzada) con regularización L2 [21, 31].

La pérdida logarítmica castiga más cuanto menor es la probabilidad que el modelo asigna a la clase real de cada hogar: asignar un 10 % a un hogar que sí es pobre cuesta mucho más que asignarle un 90 %. La regularización evita que el modelo dependa demasiado de una sola característica, y el hiperparámetro C regula su intensidad: un C menor regulariza más. Con `class_weight="balanced"`, los errores se ponderan según la frecuencia de cada clase. En el entrenamiento, cada error con un hogar pobre pesa 2,76 y cada error con uno no pobre, 0,61, así que el modelo no aprende a responder casi siempre «no pobre».

Los otros algoritmos aprenden de otra manera. El árbol y Random Forest eligen cada división para que los grupos resultantes sean lo más homogéneos posible, según la impureza de Gini. KNN no se entrena con una función de pérdida: clasifica cada hogar según los hogares más parecidos. Los hiperparámetros se ajustaron con `GridSearchCV` y validación cruzada estratificada de cinco particiones, con F1 como criterio; las grillas están en el anexo E. Todos los modelos comparten el mismo pipeline de preprocesamiento, las mismas particiones y la semilla 42. Tras la búsqueda, cada pipeline se reentrenó con todo el entrenamiento y se guardó con `joblib`.

18.2. Modelo base (baseline)

El baseline sin inteligencia artificial es la regla «**rural = pobre**», que considera pobre a todo hogar rural. Es una forma común de focalización geográfica y la más fácil de aplicar. Como referencias adicionales se reportan la regresión logística con hiperparámetros por defecto, que sirve de baseline de aprendizaje automático, y la predicción trivial «nadie es pobre».

18.3. Implementación del prototipo

El prototipo es una aplicación web en Streamlit con tres pestañas (figura 8 y anexo H). La primera, «Evaluar un hogar», es una ficha con las características observables; la probabilidad, la decisión y su explicación se actualizan con cada cambio, y un botón carga un hogar real de la prueba junto con su condición oficial para comparar. La segunda, «Evaluar una lista de

hogares», ordena por riesgo los hogares de un CSV o de una muestra real de 300 hogares y permite descargar el resultado. La tercera, «Acerca del modelo», informa el desempeño, la equidad y las limitaciones. La explicación compara cada hogar con el hogar promedio del entrenamiento. Como el puntaje de la regresión logística es aditivo, el aporte de cada columna j es exacto:

$$\text{aporte}_j = w_j (x_j - \bar{x}_j), \quad \text{logit}(p) = \text{logit}(\bar{p}) + \sum_j \text{aporte}_j, \tag{1}$$

donde $\bar{x}_j$ es el promedio de la columna en el entrenamiento y $\bar{p}$ la probabilidad del hogar promedio. Como varias variables están correlacionadas, el signo de un aporte individual puede confundir; por eso el prototipo suma los aportes en nueve grupos temáticos, lo que conserva la exactitud de la suma.

Focalización de hogares en situación de pobreza




Figura 8. Prototipo: hogar real de la ENAHO 2025 (Huancavelica), priorizado con una probabilidad de 98,2 % y pobre según el INEI, con la explicación por grupo y por característica.

19. Diseño experimental

Se diseñaron siete experimentos controlados (tabla 13). Entre ellos cambian el algoritmo y sus hiperparámetros y, en E6, el año de entrenamiento. Permanecen constantes las 36 variables, el preprocesamiento, la partición, las cinco particiones de validación, el umbral de 0,5 y la semilla. Se miden el F1 (métrica principal), la *precision*, el *recall*, el ROC-AUC y el *accuracy*. El objetivo es atribuir las diferencias de desempeño solo al algoritmo y no a diferencias en los datos o en la preparación. La métrica principal, el umbral y la regla de selección se fijaron antes de ver los resultados. La regla elige el modelo con mayor F1 medio en la validación cruzada. Si la diferencia con el segundo es menor que la desviación estándar entre particiones, se considera un empate práctico y se prefiere el modelo más interpretable, porque en una política social hay que poder explicar por qué se prioriza a un hogar [25]. H1 se acepta si, en la prueba, el modelo seleccionado obtiene un F1 mayor que la regla y comete a la vez menos errores de exclusión y de inclusión.

Tabla 13. Diseño de los experimentos (VC-5: validación cruzada estratificada de cinco particiones sobre el entrenamiento).

Exp.	Modelo	Variables	Parámetros	Evaluación	Pregunta que responde
E0	Regla «rural = pobre»	area_rural	–	Entrenamiento y prueba	¿Cuánto se logra sin inteligencia artificial?
E1	Regresión logística	36	Por defecto	VC-5 y prueba	¿Cuánto aporta un modelo sin ajustar?
E2	Regresión logística	36	GridSearchCV	VC-5 y prueba	¿Cuál es el mejor modelo lineal?
E3	Árbol de decisión	36	GridSearchCV	VC-5 y prueba	¿Ayudan las reglas no lineales?
E4	KNN	36	GridSearchCV	VC-5 y prueba	¿Sirve la similitud entre hogares?
E5	Random Forest	36	GridSearchCV	VC-5 y prueba	¿Mejora un ensamble no lineal?
E6	E2 y E5 entrenados con 2024	36	Los de E2 y E5	Hogares nuevos de 2025	¿Generaliza a otro año?

20. Evaluación

Métricas. Sean VP los hogares pobres detectados, FN los pobres excluidos (error de exclusión), FP los no pobres incluidos (error de inclusión) y VN los no pobres bien descartados. Entonces, $Precision = VP/(VP + FP)$, $Recall = VP/(VP + FN)$ y $F_1 = 2 \cdot Precision \cdot Recall / (Precision + Recall)$. Se eligió el F1 como métrica principal porque en la focalización importan los dos errores, y el F1 solo es alto si ambos son bajos. El *recall* y la *precision* se reportan por separado porque tienen consecuencias distintas: el primero mide cuántos pobres llegan al programa, y el segundo, cuántos priorizados son realmente pobres. El ROC-AUC mide la capacidad de ordenar a los hogares por riesgo sin depender del umbral [24], lo que importa porque el prototipo ordena listas. El *accuracy* se reporta, pero no se usa para decidir [23]. La matriz de confusión traduce las métricas a número de hogares.

Validación. La división entrenamiento/prueba es 80/20, estratificada y con semilla fija. No se separó un tercer conjunto: la validación cruzada estratificada de cinco particiones sobre el entrenamiento cumplió el papel de conjunto de validación, con el pipeline completo reajustado en cada partición. Como cada año de la ENAHO es un corte transversal, la división aleatoria dentro de 2025 no mezcla pasado y futuro. La generalización en el tiempo se evaluó aparte (E6), entrenando con 2024 y evaluando con los hogares nuevos de 2025. La reproducción exacta de las cifras oficiales del INEI funciona como validación externa de los datos.

Comparación e interpretabilidad. Los modelos se comparan en tablas con todas las métricas, y se explica su diferencia por el tipo de error que cometen, su sobreajuste, su interpretabilidad y su costo. La explicación global usa los coeficientes de la regresión logística y, como

contraste, la importancia de variables de Random Forest. La explicación local usa el aporte exacto de la ecuación (1), así que no se requieren métodos aproximados como SHAP o LIME.

Evaluación del artefacto, prototipo y despliegue. Siguiendo a Hevner et al. [13], el sistema también se evalúa como artefacto. Los criterios son la precisión, el tiempo de respuesta, la escalabilidad, la robustez ante entradas inválidas, la interpretabilidad y la utilidad frente a la regla. El prototipo se ejecuta localmente en Windows 11 con Python 3.10.6. Se instala con `pip install -r requirements.txt`, con versiones fijadas, y se inicia con `streamlit run app/app.py`. El modelo (`models/modelo_final.joblib`, 9 KB) se acompaña de un JSON con sus hiperparámetros, umbral, métricas y el hogar promedio usado en las explicaciones. El prototipo no guarda datos de los hogares evaluados. No se implementó una API, aunque la lógica ya está separada de la interfaz. La reproducibilidad se detalla en la sección 25.

21. Resultados

Todas las cifras provienen de los cuadernos 04 y 05 del repositorio; los resultados completos están en el anexo D.

La tabla 14 presenta los resultados de la validación cruzada (OE3). En la regresión logística, las cuatro configuraciones con balanceo de clases obtuvieron un F1 entre 0,548 y 0,552, y las no balanceadas, alrededor de 0,44. En KNN, el F1 bajó al aumentar k . Las búsquedas tardaron entre 4 y 20 s, excepto la de Random Forest (95 s). La regresión logística ajustada (E2) y Random Forest (E5) quedaron en empate práctico según la regla de selección: la diferencia de F1 es 0,000, menor que la desviación estándar entre particiones (0,010).

Tabla 14. Resultados en validación cruzada de cinco particiones (entrenamiento, 26 961 hogares).

Exp.	Modelo	F1 ($\pm$ desv.)	Precision	Recall	ROC-AUC	Accuracy
E2	Regresión logística ajustada	0,552 $\pm$ 0,010	0,421	0,801	0,860	0,764
E5	Random Forest	0,552 $\pm$ 0,014	0,465	0,679	0,853	0,800
E3	Árbol de decisión	0,500 $\pm$ 0,007	0,369	0,775	0,813	0,719
E1	Regresión logística por defecto	0,443 $\pm$ 0,021	0,633	0,341	0,859	0,845
E4	KNN	0,397 $\pm$ 0,024	0,464	0,347	0,727	0,809
E0	Regla «rural = pobre»	0,347	0,265	0,504	–	0,657
–	Predecir «nadie es pobre»	0,000	0,000	0,000	–	0,819

La tabla 15 presenta los resultados en el conjunto de prueba (OE4). Frente a la regla, la regresión logística detecta 383 hogares pobres más (974 frente a 591) y, a la vez, incluye por error a 336 hogares no pobres menos. Frente a Random Forest, detecta 130 pobres más, pero incluye 376 no pobres más. En todos los modelos, el F1 de prueba difiere en menos de 0,03 del de validación cruzada. El F1 en el propio entrenamiento fue de 0,558 para la regresión logística y de 0,713 para Random Forest, que muestra así más sobreajuste. En la curva ROC (figura 9), la regresión logística y Random Forest casi se superponen, y la regla queda por debajo de ambas. Por el balanceo de clases, la probabilidad media que entrega la regresión logística es 0,370, mientras que la proporción real de hogares pobres es 0,181. Con el umbral de 0,5 se prioriza al 35,0 % de los hogares; con 0,7, al 19,6 %, con una *precision* de 0,52 y un *recall* de 0,56 (anexo D).

La tabla 16 presenta la validación temporal (E6). Los modelos entrenados con 2024 obtienen en los hogares nuevos de 2025 prácticamente el mismo F1 que en la prueba de 2025, con diferencias de 0,006 o menos.

En la interpretación global (figura 10), varios departamentos tienen coeficientes grandes, de Puno (0,87) a Ica (−2,09). Entre las demás características, destacan por aumentar la probabilidad de pobreza el número de miembros (1,27 por desviación estándar), el dominio Lima Metropolitana (1,19), la vivienda improvisada (0,53) y la tenencia por invasión (0,46). Por reducirla destacan el teléfono fijo (−0,86), el número de artefactos (−0,75), el área rural (−0,61)

Tabla 15. Resultados en el conjunto de prueba (6 741 hogares, 1 221 pobres), umbral 0,5. FN: pobres excluidos; FP: no pobres incluidos.

Exp.	Modelo	F1	Precision	Recall	ROC-AUC	Accuracy	FN	FP
E5	Random Forest	0,549	0,455	0,691	0,849	0,794	377	1 011
E2	Regresión logística ajustada	0,544	0,413	0,798	0,853	0,758	247	1 387
E3	Árbol de decisión	0,495	0,367	0,759	0,808	0,719	294	1 597
E1	Regresión logística por defecto	0,416	0,601	0,319	0,851	0,838	832	258
E4	KNN	0,406	0,466	0,360	0,724	0,809	781	505
E0	Regla «rural = pobre»	0,334	0,255	0,484	–	0,651	630	1 723




Figura 9. Curvas ROC en el conjunto de prueba; el punto marca la regla «rural = pobre».

Tabla 16. Validación temporal: entrenamiento con la ENAHO 2024 (33 691 hogares) y evaluación con los hogares nuevos de 2025 (23 860).

Modelo	F1	Precision	Recall	ROC-AUC	Accuracy	F1 en prueba 2025
E0 Regla «rural = pobre»	0,337	0,258	0,488	–	0,661	0,334
E2 Regresión logística	0,544	0,408	0,815	0,861	0,759	0,544
E5 Random Forest	0,555	0,451	0,723	0,857	0,796	0,549

y el auto (−0,56). El coeficiente de jefa mujer es −0,17. En Random Forest, las variables más importantes son las personas por habitación, el número de artefactos, el número de miembros, el departamento y los menores de 14 años (anexo D). Para la explicación local se tomó el hogar pobre priorizado cuya probabilidad (0,789) es la mediana de su grupo: una persona de 71 años en Lima Metropolitana, con un solo artefacto y sin celular. Frente al hogar promedio (0,267), la ubicación le aporta +1,48 al puntaje, la falta de artefactos y vehículos +1,44 y su tamaño de un solo miembro −1,44, y la suma de los aportes reproduce exactamente su puntaje.

La tabla 17 muestra el desempeño por grupo. El *recall* es menor en los hogares urbanos, en los de jefa mujer y en los dominios de la costa, y Random Forest muestra el mismo patrón con valores más bajos.




Figura 10. Las 20 características con mayor coeficiente (en valor absoluto) en la regresión logística; rojo: aumentan la probabilidad de pobreza; azul: la reducen.

Tabla 17. Desempeño por grupo en el conjunto de prueba (regresión logística; última columna: *recall* de Random Forest).

Dimensión	Grupo	Hogares	Pobres	Recall	Precision	F1	Recall RF
Área	Rural	2 314	591	0,875	0,415	0,563	0,826
	Urbano	4 427	630	0,725	0,409	0,523	0,565
Sexo del jefe(a)	Jefe hombre	4 260	802	0,832	0,424	0,562	0,718
	Jefa mujer	2 481	419	0,733	0,389	0,508	0,640
Dominio	Sierra Norte	387	128	0,906	0,455	0,606	0,867
	Sierra Sur	915	164	0,878	0,398	0,548	0,762
	Sierra Centro	1 095	258	0,868	0,406	0,553	0,771
	Selva	1 420	264	0,784	0,418	0,545	0,739
	Lima Metropolitana	798	144	0,778	0,446	0,567	0,562
	Costa Norte	983	162	0,698	0,440	0,539	0,568
	Costa Centro	679	59	0,593	0,347	0,438	0,458
	Costa Sur	464	42	0,548	0,261	0,354	0,333

En la evaluación del artefacto, la regresión logística responde en unos 4 ms por hogar y evalúa los 6 741 hogares de prueba en unos 0,01 s. Su archivo pesa 9 KB, frente a 63 MB del Random Forest. Un hogar con cuatro respuestas vacías recibe una probabilidad sin errores, y los textos y códigos inválidos pasan a faltantes. Las 51 pruebas se aprueban en unos 6 s. Para la selección final (OE5), la regla fijada de antemano indica empate entre la regresión logística y Random Forest, y en ese caso favorece a la primera por ser más interpretable. El modelo final es, por lo tanto, la **regresión logística con C=1, class_weight="balanced" y umbral de 0,5**. En la demostración del prototipo (OE6) con hogares reales, el hogar típico de Lima Metropolitana recibe una probabilidad de 28,0 % y no se prioriza. En la muestra de 300 hogares, el prototipo prioriza a 102 y detecta a 41 de los 57 hogares pobres.

22. Discusión

El modelo cumplió su propósito: en hogares nunca vistos, la regresión logística obtuvo un F1 de 0,544 frente a 0,334 de la regla rural, y redujo a la vez la exclusión (247 hogares pobres fuera en lugar de 630) y la inclusión (1 387 hogares no pobres dentro en lugar de 1 723). Por lo tanto, se cumple H1 y se rechaza H0. No se trata de mover el equilibrio entre ambos errores, sino de mejorar los dos, y la mejora se mantuvo al año siguiente. La mejora tiene un límite: con una *precision* de 0,413, de cada diez hogares priorizados unos cuatro son pobres, así que el modelo reduce la filtración sin eliminarla.

El resultado se explica porque, como mostró el análisis exploratorio, ninguna característica separa las clases por sí sola, pero muchas aportan una señal débil que el modelo combina. Compensar el desbalance fue tan importante como elegir el algoritmo: solo el balanceo elevó el F1 de la regresión logística de 0,443 a 0,552, al pasar su *recall* de 0,341 a 0,801. El empate con Random Forest sugiere que la relación entre las características observables y la pobreza es principalmente aditiva: más bienes, más educación o mejores materiales reducen el riesgo, sin interacciones complejas. Ambos modelos coinciden en las señales principales (el tamaño y la composición del hogar, los bienes durables, el hacinamiento, la vivienda y la ubicación), lo que da confianza en que reflejan relaciones reales. El efecto de la ubicación no contradice que la pobreza sea mayor en el campo: a igualdad de condiciones materiales, Lima Metropolitana eleva el riesgo y el área rural lo reduce porque el INEI usa líneas de pobreza más altas donde el costo de vida es mayor [3]. Como el dominio, el departamento y el área comparten información, sus coeficientes deben leerse en conjunto y no uno por uno; por eso el prototipo los suma en el grupo «ubicación».

Estos hallazgos coinciden en parte con la literatura. Como en Brown et al. [6], la exclusión es el principal riesgo de focalizar con características observables, y por eso el balanceo, que prioriza el *recall*, resultó decisivo. McBride y Nichols [7] y Sohnesen y Stender [18] encontraron que Random Forest suele superar a los modelos tradicionales. Aquí ambos empataron, lo que coincide con Kapoor y Narayanan [12], quienes mostraron en su caso de estudio que los modelos complejos perdieron su ventaja sobre la regresión logística al corregir la fuga de información. A diferencia de lo que advirtieron Sohnesen y Stender, el desempeño se mantuvo de 2024 a 2025, aunque solo se evaluó un año de distancia. La diferencia más notoria es con los estudios peruanos, que reportan exactitudes de 98 % [9, 10], frente a un *accuracy* de 0,758 en este trabajo, que es incluso menor que el 0,819 de predecir que nadie es pobre y confirma que el *accuracy* no sirve para juzgar este problema. La brecha con esos estudios se explica por el diseño: en al menos dos de esos estudios el gasto, que define la pobreza, figura entre los predictores [10, 11]. Este proyecto lo excluye porque no está disponible al focalizar, así que su desempeño es menor, pero es el que puede esperarse en un uso real. Sí coincide con Caycho en que el número de miembros y el piso de tierra están entre los determinantes observables relevantes.

El modelo falla más en los hogares urbanos, en los de jefa mujer y en los de la costa, donde los hogares pobres suelen tener piso de cemento, agua de red y celular, igual que muchos no pobres. Como Random Forest muestra el mismo patrón, las brechas parecen provenir de la información disponible más que del algoritmo, lo que coincide con Karlan y Thuysbaert [17]: los métodos aciertan en los extremos y fallan en el medio de la distribución. En los hogares con jefa mujer influye además el coeficiente negativo de esa variable, que reduce su puntaje a igualdad de condiciones. Como en Noriega-Campero et al. [8] y Aiken et al. [19], el modelo mejora frente a la focalización geográfica, pero presenta brechas entre grupos.

En la práctica, con el umbral de 0,5 un programa priorizaría al 35 % de los hogares y llegaría a 8 de cada 10 hogares pobres; si su presupuesto solo alcanzara para el 20 %, un umbral de 0,7 ofrecería una *precision* de 0,52. El modelo permite, así, elegir el punto de operación según el presupuesto y el error que se considere más grave. Su mejor uso no es decidir de forma automática, sino ordenar listas de hogares para priorizar la verificación, con una explicación que el funcionario puede revisar y con verificación adicional en los grupos donde más se equivoca.

23. Amenazas a la validez y limitaciones

Las amenazas se organizan según la clasificación de la experimentación en ingeniería de software [32].

Validez interna. Las diferencias entre modelos se atribuyen al algoritmo porque todos comparten las variables, el preprocesamiento, las particiones, el umbral y la semilla. Además, el modelo se eligió solo con validación cruzada y el conjunto de prueba se usó una vez. Quedan cuatro amenazas. Primero, las grillas de hiperparámetros son limitadas; otras configuraciones podrían cambiar levemente las métricas, aunque difícilmente el orden entre modelos. Segundo, la ENAHO selecciona conglomerados de viviendas vecinas, y la división por hogar deja vecinos en entrenamiento y prueba: el 99,9 % de los hogares de prueba tiene vecinos en el entrenamiento. Como los vecinos comparten condiciones del entorno, las métricas podrían ser optimistas [33]. Este efecto se midió sin otro experimento, aprovechando la validación cruzada: sus particiones son bloques contiguos sin barajar, y como los hogares de un conglomerado están seguidos en el dataset, el 98,5 % de los conglomerados queda entero dentro de una sola partición. Cada partición se evalúa, por lo tanto, con vecinos que el modelo no vio. El F1 casi no cambia entre la validación cruzada y la prueba (0,552 y 0,544 en la regresión logística; 0,552 y 0,549 en Random Forest), así que los vecinos no inflan las métricas. Queda sin evaluar el desempeño en regiones completas no vistas, porque las cinco particiones incluyen los 25 departamentos. Tercero, el análisis del umbral se hizo sobre la prueba y es solo descriptivo; el umbral de trabajo se fijó antes. Cuarto, la validación temporal reutilizó los hiperparámetros elegidos con la validación cruzada de 2025, que incluía a parte de los hogares nuevos evaluados en E6; el efecto debería ser mínimo, porque los modelos se reentrenaron solo con 2024 y la regresión logística es poco sensible a C (con balanceo, su F1 varía entre 0,548 y 0,552).

Validez externa. El modelo se entrenó con una encuesta estadística. Los hogares que solicitan un programa pueden diferir de la muestra, y en una focalización real existe un incentivo a declarar menos bienes que no existe en la encuesta. Además, las métricas se calcularon sobre los hogares de la muestra, sin el factor de expansión, y la muestra tiene proporcionalmente más hogares rurales que la población; por eso describen el desempeño en la muestra y no exactamente en la población. Los resultados corresponden al Perú de 2024 y 2025, y la validación temporal cubre un solo año de distancia.

Validez de constructo. La etiqueta es la pobreza monetaria oficial, que se basa en el gasto declarado, tiene error de medición y no incluye dimensiones no monetarias. Los programas usan, en cambio, la clasificación del SISFOH, que es un concepto distinto, y el baseline es una regla geográfica simple, no el algoritmo de clasificación del SISFOH, que no se replicó. El F1 pondera igual la exclusión y la filtración, aunque sus costos sociales pueden diferir; por eso ambas se reportan también por separado. Por el balanceo, la probabilidad del modelo es un puntaje de riesgo y no una probabilidad calibrada.

Validez de conclusión. La superioridad frente a la regla es amplia (0,21 puntos de F1, unas veinte veces la desviación estándar de la regresión logística entre particiones) y se repite en validación cruzada, prueba y validación temporal. En cambio, la diferencia entre la regresión logística y Random Forest es menor que la variabilidad entre particiones, así que no se afirma que uno sea superior. No se aplicaron pruebas estadísticas formales, y las estimaciones de grupos pequeños son poco precisas (la Costa Sur tiene 42 hogares pobres en la prueba).

Otras limitaciones. Los datos son respuestas declaradas por el informante. El 12 % de los hogares tiene algún valor faltante imputado. El tamaño de la muestra basta para el modelo global, pero no para algunos subgrupos. El modelo es lineal y no capta interacciones entre características, aunque el empate con Random Forest sugiere que pesan poco. El prototipo se evaluó con pruebas automatizadas y hogares reales de la encuesta, pero no con analistas de focalización, así que su usabilidad no se midió. La ENAHO se publica con cerca de cinco meses de retraso. Por último, el trabajo se hizo en una computadora personal, lo que acotó las grillas de Random Forest.

24. Consideraciones éticas

Los microdatos de la ENAHO son anónimos, no contienen nombres ni direcciones y se publican bajo el secreto estadístico [29]. Los hogares participan de forma voluntaria y con la garantía de que sus datos se usarán con fines estadísticos. Este trabajo respeta esa finalidad: usa los datos para investigar, no intenta reidentificar hogares y no toma decisiones sobre los encuestados. El prototipo no guarda ni envía los datos que se registran. Si se aplicara a hogares reales, esos datos serían personales y su tratamiento debería cumplir la Ley de Protección de Datos Personales [34].

El análisis de equidad mostró que el modelo deja fuera a más hogares pobres urbanos, costeros y con jefa mujer. Dos variables requieren atención. El sexo del jefe(a) reduce el puntaje de los hogares con jefa mujer a igualdad de condiciones, por lo que se recomienda evaluar el modelo sin esa variable. Sin embargo, eliminarla no garantiza la equidad, porque otras variables pueden estar correlacionadas con ella [26]. El efecto de la ubicación refleja las líneas de pobreza oficiales y es legítimo, pero debe comunicarse con transparencia.

El sistema es una herramienta de apoyo a la decisión y no debe usarse para excluir hogares automáticamente. Por eso se eligió un modelo interpretable que explica cada predicción de forma exacta [25]. Además, la pestaña «Acerca del modelo» funciona como una ficha del modelo [35], que informa su desempeño, sus brechas y sus limitaciones. En cuanto a la seguridad, el prototipo valida las entradas y solo carga el modelo del propio repositorio. En cuanto a la propiedad intelectual, los datos pertenecen al INEI y se citan como fuente, el código se publica con licencia MIT y las bibliotecas usadas son de código abierto.

25. Reproducibilidad

El repositorio (anexo B) contiene el código fuente, el mecanismo de descarga de los datos, los datasets procesados, la documentación y un `requirements.txt` con las versiones exactas de las librerías. La configuración está en `src/config.py`, con la semilla 42 en la partición, los modelos y la validación. Los resultados se guardan en `results/` y los cuadernos conservan sus salidas. El entorno es Windows 11 con Python 3.10.6, y los cuadernos están preparados para Google Colab: su primera celda monta Google Drive y se ubica en la carpeta del proyecto. Además, una prueba automatizada comprueba que el modelo guardado reproduce las métricas reportadas. Para reproducir el trabajo se siguen cinco pasos:

1. Clonar el repositorio y ejecutar `pip install -r requirements.txt`.
2. Descargar la ENAHO con `python src/data/descargar.py`.
3. Ejecutar en orden los cuadernos 01 a 05, que regeneran los datasets de 2025 y 2024, los modelos, las tablas y las figuras.
4. Ejecutar `pytest` para verificar el código y las métricas.
5. Ejecutar `streamlit run app/app.py` para usar el prototipo.

26. Conclusiones

Respecto a la pregunta de investigación, un modelo de aprendizaje automático entrenado solo con características observables identifica a los hogares en situación de pobreza monetaria mejor que una regla de focalización simple. Eleva el F1 de 0,334 a 0,544, reduce a la vez los errores de exclusión y de inclusión, y mantiene su desempeño de un año a otro, por lo que se cumple H1.

Respecto al OE1, se identificó que la pobreza se asocia con el tamaño y la composición del hogar, los bienes durables, el hacinamiento, los materiales de la vivienda, la educación y la

ubicación, pero ninguna característica aislada separa a pobres de no pobres. La regla «rural = pobre» es insuficiente porque la mitad de los hogares pobres es urbana.

Respecto al OE2, el proceso de preparación construyó de forma automatizada y verificable un dataset de 33 702 hogares con 36 variables disponibles en una visita. La ausencia de fuga de información se aseguró con la exclusión de las variables monetarias, el preprocesamiento dentro del pipeline, una partición disjunta y la exclusión de los hogares del panel en la validación temporal.

Respecto al OE3, se implementaron y ajustaron cuatro algoritmos con el mismo pipeline y la misma validación cruzada, y el balanceo de clases resultó decisivo en este problema desbalanceado.

Respecto al OE4, la evaluación mostró que el modelo seleccionado mantiene en datos no vistos y en otro año el desempeño estimado en validación cruzada. También reveló brechas de equidad en los hogares urbanos, costeros y con jefa mujer.

Respecto al OE5, la regresión logística y Random Forest son equivalentes en desempeño global. Según la regla definida de antemano, se seleccionó la regresión logística, que además deja fuera a menos hogares pobres, sobreajusta menos, es más eficiente y explica cada predicción de forma exacta.

Respecto al OE6, se implementó un prototipo web funcional que evalúa hogares individuales y listas de hogares, explica cada predicción y comunica sus limitaciones. Su funcionamiento se verificó con 51 pruebas automatizadas.

27. Recomendaciones y trabajo futuro

Se recomienda usar el modelo para ordenar y priorizar la verificación de hogares, nunca para excluirllos de forma automática, dada su *precision* de 0,41. También se recomienda complementarlo con verificación adicional en los hogares urbanos, costeros y con jefa mujer, y evaluar el efecto de retirar la variable sexo del jefe(a). El umbral debería elegirse según el presupuesto de cada programa, usando un conjunto de validación y no el de prueba. Por último, el modelo debería reentrenarse con cada edición de la ENAHO, repitiendo la validación temporal y el análisis por grupos, y evaluarse con datos de solicitantes reales y con analistas de focalización, incluida su usabilidad, antes de cualquier uso operativo.

Como trabajo futuro se proponen seis líneas:

- comparar modelos de *boosting* y la calibración de probabilidades con el mismo protocolo;
- medir la estabilidad en varias ediciones de la ENAHO;
- aplicar validación cruzada por departamento o dominio para estimar el desempeño en regiones completas no vistas [33];
- extender el modelo a otras poblaciones objetivo, como adultos mayores o primera infancia;
- exponer las funciones de predicción como una API para integrarlas con los sistemas de focalización;
- desplegar el sistema en la nube con autenticación, auditoría y monitoreo del desempeño por grupo.

28 Referencias

- [1] Congreso de la República del Perú, “Ley n.º 30435, ley que crea el Sistema Nacional de Focalización (SINAFO),” Diario Oficial El Peruano, 2016.
- [2] L. Alcázar, M. Alvarado, y E. Legonía, “Evaluación de la operatividad del Sistema de Focalización de Hogares (SISFOH): evaluación del diseño, la metodología de determinación de la clasificación socioeconómica y sus procesos operativos,” Ministerio de Desarrollo e Inclusión Social, Lima,

- Perú, Inf. téc., 2017. [En línea]. Disponible en: <https://evidencia.midis.gob.pe/evaluacion-de-la-operatividad-del-sistema-de-focalizacion-de-hogares-sisfoh-evaluacion-del-diseno-la-metodologia-de-determinacion-de-la-clasificacion-socioeconomica-y-sus-procesos-operativos/>
- [3] Instituto Nacional de Estadística e Informática, “Perú: Evolución de la pobreza monetaria, 2016–2025. informe técnico,” INEI, Lima, Perú, Inf. téc., mayo 2026, consultado: 24 sep. 2026. [En línea]. Disponible en: <https://www.gob.pe/institucion/inei/informes-publicaciones/8088591-peru-evolucion-de-la-pobreza-monetaria-2016-2025>
 - [4] M. E. Grosh y J. L. Baker, “Proxy means tests for targeting social programs: Simulations and speculation,” The World Bank, Washington, DC, LSMS Working Paper 118, 1995.
 - [5] D. Coady, M. Grosh, y J. Hoddinott, “Targeting outcomes redux,” *The World Bank Research Observer*, vol. 19, n.º 1, pp. 61–85, 2004.
 - [6] C. Brown, M. Ravallion, y D. van de Walle, “A poor means test? Econometric targeting in Africa,” *Journal of Development Economics*, vol. 134, pp. 109–124, 2018.
 - [7] L. McBride y A. Nichols, “Retooling poverty targeting using out-of-sample validation and machine learning,” *The World Bank Economic Review*, vol. 32, n.º 3, pp. 531–550, 2018.
 - [8] A. Noriega-Campero, B. Garcia-Bulle, L. F. Cantu, M. A. Bakker, L. Tejerina, y A. Pentland, “Algorithmic targeting of social policies: fairness, accuracy, and distributed governance,” en *Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency (FAT*)*. ACM, 2020, pp. 241–251.
 - [9] H. A. Silva Marchan, O. J. M. Peña Cáceres, D. M. Ricalde Moran, T. Samaniego-Cobo, y C. M. Perez-Espinoza, “A machine learning study about the vulnerability level of poverty in Perú,” en *Technologies and Innovation (CITI 2022)*, ser. Communications in Computer and Information Science. Cham: Springer, 2022, vol. 1658, pp. 3–14.
 - [10] A. C. Vargas Mamani, “Application of multilayer perceptron: Analysis of socioeconomic factors of poverty in Peru,” en *Information Management and Big Data (SIMBig 2024)*, ser. Communications in Computer and Information Science. Cham: Springer, 2025, vol. 2496, pp. 110–123.
 - [11] C. T. Caycho Chumpitaz, “Medición de la pobreza en el Perú: un análisis multivariante desde un enfoque multidimensional,” *Desafíos: Economía y Empresa*, n.º 5, pp. 143–159, 2024.
 - [12] S. Kapoor y A. Narayanan, “Leakage and the reproducibility crisis in machine-learning-based science,” *Patterns*, vol. 4, n.º 9, p. 100804, 2023.
 - [13] A. R. Hevner, S. T. March, J. Park, y S. Ram, “Design science in information systems research,” *MIS Quarterly*, vol. 28, n.º 1, pp. 75–105, 2004.
 - [14] K. Peffers, T. Tuunanen, M. A. Rothenberger, y S. Chatterjee, “A design science research methodology for information systems research,” *Journal of Management Information Systems*, vol. 24, n.º 3, pp. 45–77, 2007.
 - [15] C. Schröer, F. Kruse, y J. M. Gómez, “A systematic literature review on applying CRISP-DM process model,” *Procedia Computer Science*, vol. 181, pp. 526–534, 2021.
 - [16] S. Amershi, A. Begel, C. Bird, R. DeLine, H. Gall, E. Kamar, N. Nagappan, B. Nushi, y T. Zimmermann, “Software engineering for machine learning: A case study,” en *Proceedings of the 41st IEEE/ACM International Conference on Software Engineering: Software Engineering in Practice (ICSE-SEIP)*. IEEE, 2019, pp. 291–300.
 - [17] D. Karlan y B. Thuysbaert, “Targeting ultra-poor households in Honduras and Peru,” *The World Bank Economic Review*, vol. 33, n.º 1, pp. 63–94, 2019.
 - [18] T. P. Sohnesen y N. Stender, “Is random forest a superior methodology for predicting poverty? An empirical assessment,” *Poverty & Public Policy*, vol. 9, n.º 1, pp. 118–133, 2017.
 - [19] E. Aiken, S. Bellue, D. Karlan, C. Udry, y J. E. Blumenstock, “Machine learning and phone data can improve targeting of humanitarian aid,” *Nature*, vol. 603, n.º 7903, pp. 864–870, 2022.
 - [20] S. Russell y P. Norvig, *Artificial Intelligence: A Modern Approach*, 4th ed. Hoboken, NJ: Pearson, 2021.

- [21] T. Hastie, R. Tibshirani, y J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed. New York: Springer, 2009.
- [22] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, n.º 1, pp. 5–32, 2001.
- [23] H. He y E. A. Garcia, “Learning from imbalanced data,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 21, n.º 9, pp. 1263–1284, 2009.
- [24] T. Fawcett, “An introduction to ROC analysis,” *Pattern Recognition Letters*, vol. 27, n.º 8, pp. 861–874, 2006.
- [25] C. Rudin, “Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead,” *Nature Machine Intelligence*, vol. 1, n.º 5, pp. 206–215, 2019.
- [26] N. Mehrabi, F. Morstatter, N. Saxena, K. Lerman, y A. Galstyan, “A survey on bias and fairness in machine learning,” *ACM Computing Surveys*, vol. 54, n.º 6, pp. 1–35, 2021.
- [27] Instituto Nacional de Estadística e Informática, “Microdatos de la Encuesta Nacional de Hogares (ENAHOG) 2024 y 2025: módulos 01, 02, 03, 18, 34 y 37,” Portal de microdatos del INEI, 2026, consultado: 24 sep. 2026. [En línea]. Disponible en: <https://proyectos.inei.gob.pe/microdatos/>
- [28] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, y É. Duchesnay, “Scikit-learn: Machine learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011. [En línea]. Disponible en: <https://jmlr.org/papers/v12/pedregosa11a.html>
- [29] Presidencia de la República del Perú, “Decreto legislativo n.º 604, ley de organización y funciones del Instituto Nacional de Estadística e Informática,” Diario Oficial El Peruano, 1990.
- [30] T. Gebru, J. Morgenstern, B. Vecchione, J. W. Vaughan, H. Wallach, H. Daumé III, y K. Crawford, “Datasheets for datasets,” *Communications of the ACM*, vol. 64, n.º 12, pp. 86–92, 2021.
- [31] scikit-learn developers, “Linear models: 1.1.11. Logistic regression,” scikit-learn User Guide, 2026, consultado: 25 sep. 2026. [En línea]. Disponible en: https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression
- [32] C. Wohlin, P. Runeson, M. Höst, M. C. Ohlsson, B. Regnell, y A. Wesslén, *Experimentation in Software Engineering*. Berlin, Heidelberg: Springer, 2012.
- [33] D. R. Roberts, V. Bahn, S. Ciuti, M. S. Boyce, J. Elith, G. Guillera-Aroita, S. Hauenstein, J. J. Lahoz-Monfort, B. Schröder, W. Thuiller, D. I. Warton, B. A. Wintle, F. Hartig, y C. F. Dormann, “Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure,” *Ecography*, vol. 40, n.º 8, pp. 913–929, 2017.
- [34] Congreso de la República del Perú, “Ley n.º 29733, ley de protección de datos personales,” Diario Oficial El Peruano, 2011.
- [35] M. Mitchell, S. Wu, A. Zaldivar, P. Barnes, L. Vasserman, B. Hutchinson, E. Spitzer, I. D. Raji, y T. Gebru, “Model cards for model reporting,” en *Proceedings of the Conference on Fairness, Accountability, and Transparency (FAT*)*. ACM, 2019, pp. 220–229.

29. Anexos

Anexo A. Descripción completa del dataset

El dataset se construye con `src/features/construir.py` a partir de cinco módulos de la ENAHO, unidos por la llave del hogar (CONGLOME, VIVIENDA, HOGAR), según las reglas de la tabla 18. El dataset de 2024 se construye con el mismo código (33 691 hogares) y reproduce la pobreza oficial de ese año: 27,6 % nacional, 24,8 % urbana y 39,3 % rural.

Tabla 18. Reglas de construcción del dataset.

Módulo	Reglas
Sumaria (34)	Tamaño del hogar (MIEPERHO); dominio; área rural si $ESTRATO \geq 6$; departamento con los dos primeros dígitos del ubigeo; objetivo pobre = 1 si $POBREZA \leq 2$. El factor de expansión y la condición oficial se conservan solo para el análisis
Vivienda (100)	Tipo, paredes, piso, techo, tenencia, agua, desagüe, electricidad, combustible y comunicaciones; el código 99 de habitaciones es faltante
Miembros (200)	Solo residentes habituales (P204 = 1), sin trabajadores del hogar ni pensionistas (P203 8 y 9); conteos por edad y datos del jefe(a)
Educación (300)	Nivel del jefe(a) y máximo de los adultos en la escala ordinal P301A (1 a 11); los códigos 12 y 99 son faltantes
Equipamiento (612)	1 = sí, 2 = no, 9 = faltante; 9 columnas 0/1 de artículos seleccionados y el total de artículos entre los 28 de la lista
Derivadas y validez	Personas por habitación y tasa de dependencia, con una función compartida con el prototipo; los códigos categóricos que no están en el diccionario del INEI pasan a faltante

Anexo B. Código fuente y repositorio

El código fuente completo está en <https://github.com/BrensNina/proyecto-pobreza-ia>, con la estructura recomendada por el curso. El README explica cómo instalar el proyecto, obtener los datos, entrenar el modelo, reproducir los experimentos y ejecutar el prototipo.

```
proyecto-pobreza-ia/
|-- README.md, LICENSE, requirements.txt, pytest.ini
|-- data/      raw/ (descarga) - processed/ (hogares, particion, panel) - README.md
|-- notebooks/ 01_data_understanding ... 05_evaluation (.ipynb)
|-- src/       data/ - features/ - preprocessing/ - models/ - evaluation/ - config.py
|-- app/       app.py (prototipo Streamlit)
|-- tests/     51 pruebas con pytest
|-- models/    modelo_final.joblib + metadatos (JSON)
|-- results/   figuras/ - tablas/
|-- docs/      diccionario de datos - diagramas/ (Mermaid) - capturas/
|-- paper/     paper.pdf (este artículo)
```

Anexo C. Diccionario de datos

Tabla 19. Diccionario de datos del dataset de hogares.

Variable	Tipo	Origen ENAHO	Descripción
CONGLOME	Identificación (no entra al modelo)	Todas	Número de conglomerado (parte de la llave del hogar)
VIVIENDA	Identificación (no entra al modelo)	Todas	Número de vivienda (parte de la llave del hogar)

Variable	Tipo	Origen ENAH	Descripción
HOGAR	Identificación (no entra al modelo)	Todas	Número de hogar (parte de la llave del hogar)
ubigeo	Identificación (no entra al modelo)	Sumaria	Código de ubicación geográfica del INEI (departamento, provincia, distrito)
factor07	Identificación (no entra al modelo)	Sumaria	Factor de expansión del hogar; solo para estimaciones poblacionales
pobreza_inei	Identificación (no entra al modelo)	Sumaria POBREZA	Condición de pobreza oficial: 1 pobre extremo, 2 pobre no extremo, 3 no pobre
n_miembros	Númerica	Sumaria MIEPERHO	Número de miembros del hogar
n_habitaciones	Númerica	Mód. 100 P104	Habitaciones de la vivienda, sin contar baño, cocina ni pasadizos
personas_por_habitacion	Númerica	Derivada	$n_miembros / n_habitaciones$ (hacinamiento)
jefe_edad	Númerica	Mód. 200 P208A	Edad del jefe(a) del hogar en años
n_menores_14	Númerica	Mód. 200 P208A	Miembros menores de 14 años
n_mayores_65	Númerica	Mód. 200 P208A	Miembros de 65 años o más
tasa_dependencia	Númerica	Derivada	$(\text{menores de 14} + \text{mayores de 65}) / \text{miembros de 14 a 64 años}$
educacion_jefe	Númerica	Mód. 300 P301A	Nivel educativo del jefe(a), escala ordinal de 1 (sin nivel) a 11 (posgrado)
max_educacion_adultos	Númerica	Mód. 300 P301A	Máximo nivel educativo entre los miembros de 18 años o más
n_equipos	Númerica	Mód. 612 P612	Número de artefactos y vehículos que posee el hogar
tipo_vivienda	Categórica	Mód. 100 P101	Tipo de vivienda
material_paredes	Categórica	Mód. 100 P102	Material predominante de las paredes exteriores
material_piso	Categórica	Mód. 100 P103	Material predominante de los pisos
material_techo	Categórica	Mód. 100 P103A	Material predominante de los techos
tenencia_vivienda	Categórica	Mód. 100 P105A	Régimen de tenencia de la vivienda
fuentes_agua	Categórica	Mód. 100 P110	Procedencia principal del agua
desague	Categórica	Mód. 100 P111A	Conexión del servicio higiénico
combustible_cocina	Categórica	Mód. 100 P113A	Combustible usado con mayor frecuencia para cocinar
dominio	Categórica	Sumaria DOMINIO	Dominio geográfico de la ENAHO (costa, sierra, selva y Lima Metropolitana)
departamento	Categórica	Sumaria UBIGEO	Departamento (dos primeros dígitos del ubigeo)
area_rural	Binaria (0/1)	Sumaria ESTRATO	1 si el hogar está en área rural (estratos 6 a 8)
jefe_mujer	Binaria (0/1)	Mód. 200 P207	1 si el jefe del hogar es mujer
tiene_electricidad	Binaria (0/1)	Mód. 100 P1121	1 si el hogar tiene alumbrado eléctrico
tiene_telefono_fijo	Binaria (0/1)	Mód. 100 P1141	1 si el hogar tiene teléfono fijo
tiene_celular	Binaria (0/1)	Mód. 100 P1142	1 si el hogar tiene teléfono celular
tiene_tv_cable	Binaria (0/1)	Mód. 100 P1143	1 si el hogar tiene TV por cable o satelital

Variable	Tipo	Origen ENAH	Descripción
tiene_internet	Binaria (0/1)	Mód. 100 P1144	1 si el hogar tiene conexión a internet (fija o móvil)
tiene_radio	Binaria (0/1)	Mód. 612	1 si el hogar tiene radio
tiene_tv_color	Binaria (0/1)	Mód. 612	1 si el hogar tiene TV a color
tiene_computadora	Binaria (0/1)	Mód. 612	1 si el hogar tiene computadora o laptop
tiene_cocina_gas	Binaria (0/1)	Mód. 612	1 si el hogar tiene cocina a gas
tiene_refrigeradora	Binaria (0/1)	Mód. 612	1 si el hogar tiene refrigeradora o congeladora
tiene_lavadora	Binaria (0/1)	Mód. 612	1 si el hogar tiene lavadora de ropa
tiene_microondas	Binaria (0/1)	Mód. 612	1 si el hogar tiene horno microondas
tiene_auto	Binaria (0/1)	Mód. 612	1 si el hogar tiene auto o camioneta
tiene_motocicleta	Binaria (0/1)	Mód. 612	1 si el hogar tiene motocicleta
pobre	Binaria (0/1)	Sumaria POBREZA	VARIABLE OBJETIVO: 1 si el hogar es pobre (POBREZA 1 o 2), 0 si no es pobre

Anexo D. Resultados completos

Tabla 20. Validación cruzada completa (medias de las cinco particiones; desv.: desviación estándar).

Experimento	F1	desv.	Prec.	Recall	AUC	desv.	Acc.	Hiperparámetros	s
E2 Regresión logística	0,552	0,010	0,421	0,801	0,860	0,007	0,764	C=1,	20
E5 Random Forest	0,552	0,014	0,465	0,679	0,853	0,008	0,800	class_weight=balanced,	95
E3 Árbol de decisión	0,500	0,007	0,369	0,775	0,813	0,004	0,719	max_depth=20,	11
E1 Regresión logística (defecto)	0,443	0,021	0,633	0,341	0,859	0,006	0,845	min_samples_leaf=5	4
E4 KNN	0,397	0,024	0,464	0,347	0,727	0,011	0,809	class_weight=None	14
E0 Regla 'rural = pobre'	0,347	–	0,265	0,504	–	–	0,657	n_neighbors=3,	–
								weights=distance	

Tabla 21. Los 20 coeficientes de mayor magnitud de la regresión logística final (numéricas estandarizadas).

Columna del modelo	Coef.	Odds
n_miembros	1,267	3,552
dominio: Lima Metropolitana	1,186	3,276
departamento: Puno	0,872	2,391
departamento: Cajamarca	0,800	2,225
departamento: La Libertad	0,768	2,156
departamento: Pasco	0,675	1,964
departamento: Tacna	0,645	1,907
tipo_vivienda: Vivienda improvisada	0,527	1,694
departamento: Arequipa	0,471	1,602
tenencia_vivienda: Propia, por invasión	0,459	1,582
tipo_vivienda: Casa de vecindad	-0,531	0,588
departamento: Junín	-0,558	0,572
tiene_auto	-0,561	0,571
area_rural	-0,609	0,544
departamento: Ucayali	-0,675	0,509
n_equipos	-0,751	0,472
tiene_telefono_fijo	-0,856	0,425
departamento: Madre de Dios	-1,144	0,319
tenencia_vivienda: Cedida por el trabajo	-1,416	0,243
departamento: Ica	-2,086	0,124

Tabla 22. Las 20 variables más importantes en Random Forest (suma de sus columnas One-Hot).

Variable	Importancia
Personas por habitación	0,108
Artefactos y vehículos	0,093
Miembros del hogar	0,080
Departamento	0,056
Menores de 14 años	0,052
Piso	0,046
Mayor educación entre los adultos	0,046
Educación del jefe(a)	0,041
Edad del jefe(a) del hogar	0,040
Computadora	0,039
Dominio geográfico	0,039
Tasa de dependencia	0,038
Paredes	0,033
Combustible para cocinar	0,033
Refrigeradora	0,032
Techo	0,031
Servicio higiénico	0,025
Lavadora	0,022
Habitaciones	0,020
Tenencia de la vivienda	0,015

Tabla 23. Efecto del umbral de decisión en la regresión logística (conjunto de prueba). Análisis descriptivo: el umbral de trabajo es 0,5.

Umbral	Precision	Recall	F1	Hogares priorizados (%)
0,1	0,247	0,991	0,396	72,6
0,2	0,289	0,962	0,444	60,4
0,3	0,330	0,932	0,487	51,2
0,4	0,369	0,875	0,519	43,0
0,5	0,413	0,798	0,544	35,0
0,6	0,464	0,702	0,559	27,4
0,7	0,516	0,557	0,535	19,6
0,8	0,567	0,381	0,456	12,2
0,9	0,653	0,191	0,295	5,3

Anexo E. Configuración de los experimentos

Todos los experimentos usan la semilla 42, una proporción de prueba de 0,20 estratificada por pobre, las mismas cinco particiones estratificadas de validación cruzada (bloques contiguos sin barajar, con `cv=5`), `GridSearchCV` con `scoring="f1"` y un umbral de 0,5. El preprocesamiento usa la mediana y `StandardScaler` en las variables numéricas, la moda en las binarias, y la moda y `OneHotEncoder(handle_unknown="ignore")` en las categóricas. La validación temporal entrena con la ENAHO 2024 completa y evalúa con los 23 860 hogares de 2025 que no pertenecen al panel. La configuración está en `src/config.py`, `src/models/modelos.py` y `models/modelo_final_metadatos.json`. La tabla 24 presenta las grillas de hiperparámetros.

Tabla 24. Grillas de hiperparámetros y configuración elegida.

Modelo	Grilla explorada	Configuración elegida
Regresión logística	$C \in \{0,01; 0,1; 1; 10\}$; <code>class_weight</code> $\in \{\text{None}, \text{balanced}\}$; <code>max_iter</code> =3000 (8 combinaciones)	$C=1$, <code>balanced</code>
Árbol de decisión	<code>max_depth</code> $\in \{4, 6, 8, 10, 12\}$; <code>min_samples_leaf</code> $\in \{1, 20, 50, 100\}$; <code>class_weight</code> (40)	Profundidad 6, hojas de 20, <code>balanced</code>
KNN	<code>n_neighbors</code> $\in \{3, 5, 15, 25, 51\}$; <code>weights</code> $\in \{\text{uniform}, \text{distance}\}$ (10)	$k = 3$, <code>distance</code>
Random Forest	300 árboles; <code>max_depth</code> $\in \{12, 20, \text{None}\}$; <code>min_samples_leaf</code> $\in \{2, 5, 10\}$; <code>class_weight</code> (18)	Profundidad 20, hojas de 5, <code>balanced</code>

Anexo F. Instrumentos utilizados

El instrumento de recolección es el cuestionario de la ENAHO, aplicado por el INEI mediante entrevista directa. La tabla 25 relaciona las preguntas usadas con los campos de la ficha del prototipo, que es el instrumento de registro del sistema propuesto.

Tabla 25. Preguntas de la ENAHO y campos de la ficha del prototipo.

Pregunta ENAHO	Contenido	Campo del prototipo
P101–P105A	Tipo de vivienda, materiales, habitaciones y tenencia	Pestaña «Vivienda»
P110–P113A	Agua, servicio higiénico, alumbrado y combustible	Pestaña «Servicios»
P1141–P1144	Teléfono fijo, celular, TV por cable e internet	Pestaña «Servicios»
P612N, P612	Tenencia de 28 artículos del hogar	Pestaña «Artefactos y vehículos»
P203–P208A	Parentesco, residencia, sexo y edad de los miembros	Composición del hogar y datos del jefe(a)
P301A	Nivel educativo alcanzado	Educación del jefe(a) y de los adultos
UBIGEO, DOMINIO, ESTRATO	Ubicación del hogar	Departamento, dominio y área
POBREZA	Condición de pobreza (INEI)	Variable objetivo; no se pide en la ficha

Anexo G. Diagramas UML

Las fuentes en Mermaid de los diagramas están en `docs/diagramas/`.




Figura 11. Diagrama de casos de uso.




Figura 12. Diagrama de componentes.




Figura 13. Diagrama de secuencia del caso de uso «Evaluar un hogar».




Figura 14. Diagrama de secuencia del caso de uso «Evaluar una lista de hogares».

Anexo H. Capturas del prototipo

:

Focalización de hogares en situación de pobreza

Prototipo de apoyo a la decisión · Regresión logística entrenada con la ENAHO 2025 (INEI)

Evaluar un hogar Evaluación una lista de hogares Acerca del modelo

Un programa social suele partir de una lista de hogares candidatos. El prototipo calcula la probabilidad de pobreza de cada uno y los ordena de mayor a menor, para verificar primero a los de mayor riesgo.

Datos a evaluar

Muestra real: 300 hogares de prueba de la ENAHO 2025 Subir un archivo CSV

Hogares evaluados

300

Priorizados (probabilidad ≥ 50 %)

102 (34,0 %)

Hogares pobres detectados (INEI)

41 de 57

De los 102 hogares priorizados, 41 son pobres según el INEI. Los hogares pobres no priorizados son errores de exclusión: deben cubrirse con otros mecanismos, como la solicitud directa del hogar.

Orden	CONGLOME	VIVIENDA	HOGAR	Departamento	Área	Probabilidad de pobreza	Priorizar	Condición INEI
1	18752	122	11	Loreto	Rural	98,96 %	Sí	No pobre
2	18683	25	11	Loreto	Urbana	98,53 %	Sí	Pobre
3	17295	125	11	Junín	Rural	98,44 %	Sí	No pobre
4	18778	3	11	Loreto	Rural	96,77 %	Sí	Pobre
5	17907	12	22	Lima	Urbana	94,83 %	Sí	No pobre
6	16152	74	11	Cajamarca	Rural	94,57 %	Sí	Pobre
7	16662	180	11	Huancavelica	Rural	92,88 %	Sí	Pobre
8	16668	132	11	Huánuco	Urbana	92,01 %	Sí	Pobre
9	15304	1	11	Áncash	Urbana	91,88 %	Sí	Pobre
10	19955	29	11	Tacna	Urbana	91,15 %	Sí	Pobre
11	15473	34	11	Apurímac	Rural	90,94 %	Sí	No pobre

Descargar resultados (CSV)

Figura 15. Pestaña «Evaluar una lista de hogares» con la muestra real de 300 hogares de la ENAHO 2025, ordenada por probabilidad.

Focalización de hogares en situación de pobreza

Prototipo de apoyo a la decisión - Regresión logística entrenada con la ENAHO 2025 (INEI)

Evaluar un hogar Evaluar una lista de hogares [Acerca del modelo](#)

¿Qué hace este prototipo?

Estima la **probabilidad de que un hogar sea pobre** según la definición oficial del INEI (pobreza monetaria), usando **solo características observables**: vivienda, servicios, bienes, composición del hogar, educación y ubicación. Así apoya la **focalización de programas sociales** cuando no se conoce el gasto del hogar, que es costoso de medir.

Desempeño

Métrica	Modelo - prueba ENAHO 2025	Modelo - entrenado 2024, evaluado 2025	Regla «rural = pobre» - prueba
F1 (métrica principal)	0,544	0,544	0,334
Recall: hogares pobres detectados	0,798	0,815	0,484
Precisión: priorizados que son pobres	0,413	0,408	0,255
ROC-AUC: capacidad de ordenar por riesgo	0,853	0,861	—
Accuracy	0,758	0,759	0,651

Frente a la regla sin IA, el modelo detecta más hogares pobres y, a la vez, comete menos errores de inclusión. Entrenado con un año, mantiene su desempeño al año siguiente.

Equidad: ¿a quiénes deja fuera?

Dimensión	Grupo	Hogares pobres en la prueba	Pobres detectados
Área	Rural		591 87,5 %
Área	Urbano		630 72,5 %
Sexo del jefe(a)	Jefa mujer		419 73,3 %
Sexo del jefe(a)	Jefe hombre		802 83,2 %
Dominio	Costa Centro		59 59,3 %
Dominio	Costa Norte		162 69,8 %
Dominio	Costa Sur		42 54,8 %
Dominio	Lima Metropolitana		144 77,8 %
Dominio	Selva		264 78,4 %
Dominio	Sierra Centro		258 86,8 %
Dominio	Sierra Norte		128 90,6 %
Dominio	Sierra Sur		164 87,8 %

El modelo deja fuera a más hogares pobres en zonas urbanas, en hogares con jefe mujer y en la costa. En esos grupos se recomienda una verificación adicional.

Uso responsable y limitaciones

- Es una herramienta de **apoyo a la decisión**: prioriza hogares para una verificación. **No reemplaza** la clasificación socioeconómica oficial ni decide por sí sola quién recibe un programa.
- Aproximadamente **2 de cada 10 hogares pobres no son priorizados** (errores de exclusión) y más de la mitad de los priorizados no son pobres (errores de inclusión). Por eso la verificación es indispensable.
- La probabilidad es un **puntaje de riesgo**: por el balanceo de clases, el modelo entrega valores más altos que la frecuencia real de pobreza (en promedio 0,37 frente a 0,18). Sirve para ordenar hogares y compararlos con el umbral, no como la proporción exacta de hogares pobres.
- La ubicación influye en la predicción porque el INEI usa líneas de pobreza distintas según el costo de vida de cada zona. El mismo hogar puede tener distinta probabilidad en Lima que en otra región.
- El modelo aprende de la ENAHO; si las condiciones del país cambian, debe **reentrenarse** con datos recientes.
- La ficha no guarda ni envía datos de los hogares: todo se calcula en el momento.

Ficha técnica

- **Modelo**: Regresión logística (E2), `<x>`, `<class_weight="balanced">`.
- **Umbral de decisión**: 0,5.
- **Datos de entrenamiento**: ENAHO 2025 (INEI), 26 961 hogares de entrenamiento.
- **Variables predictoras**: 36 características observables.
- **scikit-learn**: 1.7.2 - **fecha del modelo**: 2025-09-24.
- **Autor**: Nina Anchapuri Brens Fabrizio Leandro. Curso de Inteligencia Artificial, Ingeniería Informática, Universidad Nacional Federico Villarreal.

Figura 16. Pestaña «Acerca del modelo»: desempeño, equidad, uso responsable y ficha técnica.

Anexo I. Matriz de trazabilidad final

Tabla 26. Matriz de trazabilidad final.

Obj.	Actividad	Artefacto	Evidencia	Resultado	Sección
OE1	Análisis del problema, literatura y análisis exploratorio	Árbol de problemas; cuadernos 01 y 02	Tabla 1; figuras 1 y 4–6	Problema caracterizado; factores asociados; regla simple insuficiente	5, 6, 10 y 16.3
OE2	Preparación de datos y control de fuga	Dataset, pipeline, partición y marca de panel	Tablas 7, 8 y 9; pruebas unitarias	33 702 hogares y 36 variables sin fuga	15 y 16
OE3	Desarrollo de los modelos	<code>src/models</code> , cuaderno 04, modelos guardados	Tablas 12, 14 y 24	Cuatro modelos ajustados; balanceo decisivo	18 y 21
OE4	Experimentos y evaluación	Protocolo E0–E6; cuaderno 05	Tablas 15, 16 y 17	F1 de 0,544 frente a 0,334; estable en otro año; brechas identificadas	19, 20 y 21
OE5	Comparación y selección	Regla de selección fijada de antemano	Tablas 14 y 15	Regresión logística seleccionada (empate con Random Forest)	21 y 22
OE6	Prototipo	<code>app/app.py</code> y 51 pruebas	Figura 8, tabla 11 y anexo H	Artefacto que predice, explica y prioriza	17.1, 18.3 y 21